

حمله توزیع شده منع سرویس (DDoS) در شبکه های نرم افزار محور (SDN) مروی بر مجموعه داده های باز، بردارهای حمله و راهبردهای کاهش دهنده

Winston Hill¹ · Yaa Takyiwaa Acquaah¹ · Janelle Mason¹ · Daniel Limbrick¹ · Stephanie Teixeira-Poit¹ · Carla Coates¹. Kaushik Roy¹

Received: 25 June 2024 / Accepted: 26 August 2024

Published online: 31 August 2024

© The Author(s) 2024  OPEN

چکیده

حملات توزیع شده منع سرویس (DDoS) تهدیدی جدی برای شبکه های نرم افزار محور (SDN) بوده و اغلب توسط عاملان مخرب به کار گرفته می شوند SDN. به عنوان یک الگوی برجسته شبکه ظهور کرده است و با جدا کردن صفحه کنترل و داده، امکان کنترل و برنامه پذیری بیشتری بر شبکه فراهم می کند. در مقایسه با شبکه های سنتی، SDN راه حل های پویا، چابک، مقرن و به صرفه و قابل مدیریت ارائه می دهد. با این حال، یک ضعف قابل توجه SDN این است که کنترل کننده مرکزی به یک سطح حمله آسیب پذیر تبدیل می شود و آن را در برابر تصرف کامل شبکه از طریق حملات DDoS آسیب پذیر می سازد. نوآوری این مقاله گردآوری منابعی است که برای کاهش حملات DDoS در محیط های SDN مورد استفاده قرار خواهد گرفت. این مقاله بر بررسی مجموعه داده های باز شامل حملات DDoS و همچنین بررسی تکنیک ها و چارچوب های تشخیص و کاهش حمله تمرکز دارد. با تحلیل راهبردهای مختلف تشخیص و مقابله، مدیران شبکه و متخصصان امنیت می توانند تصمیمات آگاهانه تری برای افزایش استحکام و تاب آوری محیط های SDN در برابر تهدیدات تکامل یابنده DDoS اتخاذ کنند.

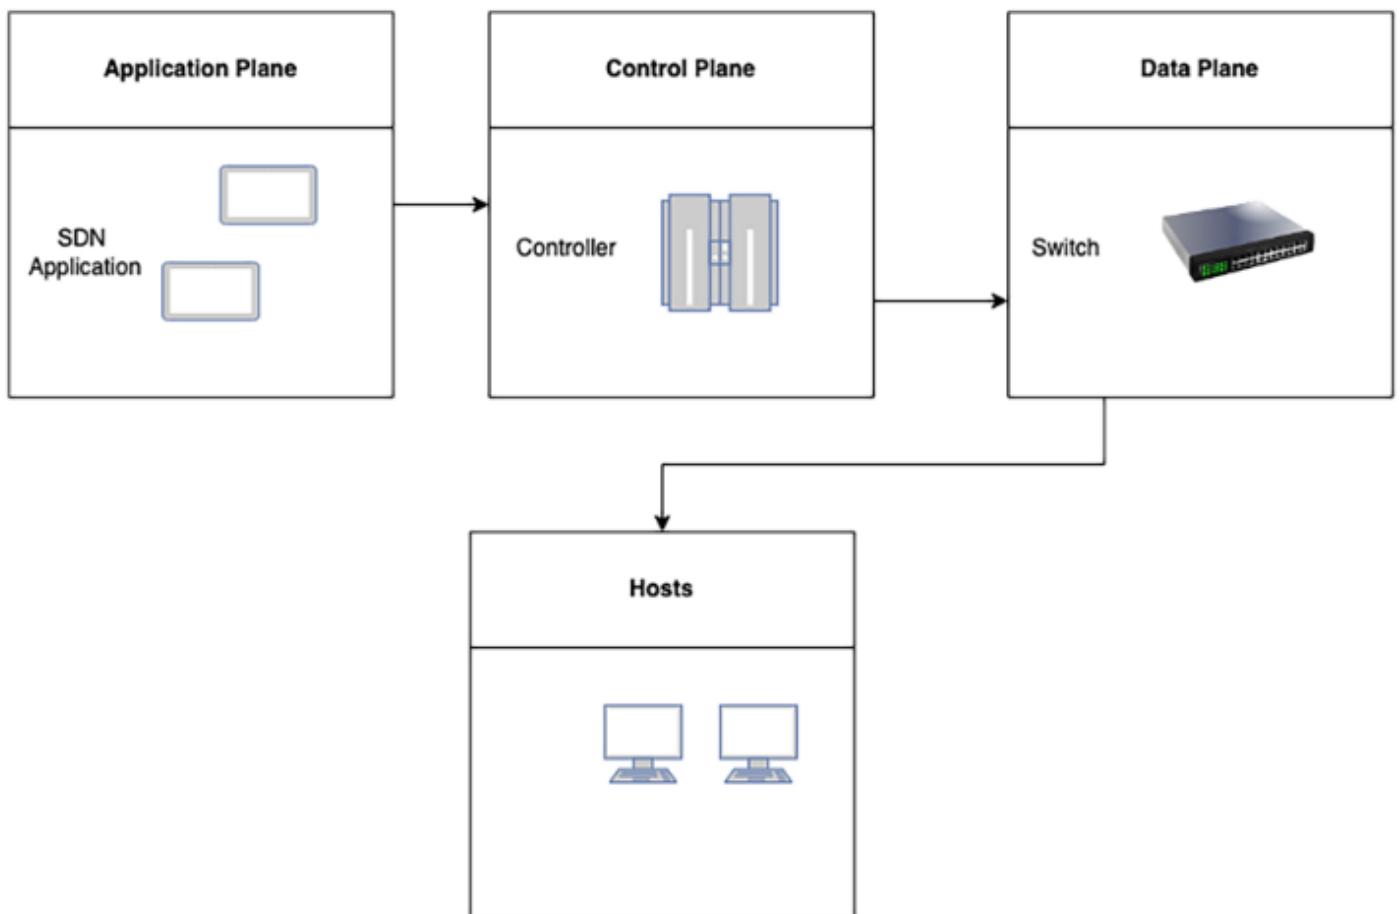
واژه های کلیدی: شبکه نرم افزار محور، حملات توزیع شده منع سرویس، مجموعه داده های باز

۱. مقدمه

شبکه های توزیع شده سنتی به سامانه های به هم پیوسته ای اشاره دارند که در آن منابع محاسباتی، داده ها و وظایف به جای متمرکز بودن در یک مکان واحد، در میان چندین گره توزیع شده اند. این شبکه ها طی دهه ها نقش بنیادی در تسهیل ارتباطات، اشتراک گذاری منابع و همکاری در محیط های مختلف محاسباتی ایفا کرده اند. در شبکه های توزیع شده سنتی، هر گره به طور مستقل عمل می کند و از طریق پروتکل های تعریف شده با سایر گره ها ارتباط برقرار می کند، که این امر امکان تصمیم گیری غیر متمرکز و عملکرد تحمل پذیر در برابر خطای فراهم می سازد. نمونه هایی از شبکه های توزیع شده سنتی شامل معماری های کاربر- سرویس دهنده، شبکه های همتا (P2P) و سامانه های فایل توزیع شده هستند که نقش های مهمی در کاربردهای مانند میزبانی وب، تحویل محتوا و محاسبات توزیع شده داشته اند. در شبکه های توزیع شده سنتی، صفحه داده و صفحه کنترل با استفاده از دستگاه های سخت افزاری مانند روتراها و سوئیچ های پیاده سازی می شوند. اپراتورهای شبکه، سیاست های ترافیکی را برای هر دستگاه پیکربندی می کنند که شامل کیفیت خدمات، مسیر یابی و سوئیچینگ است. با این حال، شبکه نرم افزار محور (SDN) با معرفی رویکردی انعطاف پذیر و قابل مدیریت تر، قصد دارد محدودیت های شبکه سازی سنتی را برطرف کند SDN. صفحه کنترل و صفحه داده را از هم جدا می کند و این امر امکان تنظیم پذیری بیشتر و سهولت مدیریت را فراهم می سازد. جداسازی صفحات مختلف در شکل ۱ نشان داده شده است. SDN مزایایی همچون کنترل متمرکز از طریق یک دستگاه راه دور به نام کنترل کننده این جداسازی صفحه کنترل و صفحه داده، مدیریت کارآمد سامانه شبکه را ارتقا می دهد و به روزرسانی ها و تغییرات را ساده تر کرده و احتمال خطا های انسانی را کاهش می دهد SDN. همچنین قابلیت بی نیازی از فروشنده را ارائه می دهد و به مدیران IT اجازه می دهد از دستگاه های مختلف شبکه استفاده کنند و بدون محدودیت زیرساخت را ارتفا دهند. کنترل کننده SDN دیدی جامع از کل شبکه فراهم می کند و دیدپذیری و کنترل را افزایش می دهد. در حالی که SDN با ایجاد امکان برنامه پذیری، فناوری شبکه سازی را متحول کرده است، آسیب پذیری های جدیدی نیز معرفی شده اند. در شکل ۱ سطح حمله نشان داده شده است و نقطه ورود انواع حملات را نمایش می دهد. یکی از چالش برانگیزترین حملات در شبکه های SDN، حمله توزیع شده منع سرویس (DDoS) است. حافظه کنترل کننده و سوئیچ های را هدف قرار می دهد و باعث غیرفعال شدن پهنه ای باند شبکه و منابع سرور شده و عملیات عادی کاربران را مختل می کند. حملات DDoS بسیار مخرب و هماهنگ هستند و از چندین ماشین به خطر افتاده برای انجام همزمان حملات منع سرویس علیه یک هدف استفاده می کنند. این امر موجب تخلیه منابع و فروپاشی سامانه شده و خدمات هدف را برای کاربران قانونی غیرقابل دسترس می سازد.

مهاجمان از حملات DDoS برای اهداف مختلفی استفاده می‌کنند، از جمله منافع سیاسی یا مالی، ایجاد اختلالات کوچک یا حتی اختلالات گسترده. چنین حملاتی می‌توانند منجر به از دست دادن سودهای تجاری و اعتماد کاربران به خدمات آسیب‌دیده شوند. یک حمله DDoS یورشی هم‌اگنگ علیه دسترس پذیری خدمات ارائه شده توسط یک سامانه یا شبکه هدف است که از طریق شبکه‌ای از سامانه‌های محاسباتی به خطر افتاده اجرا می‌شود. هدف حمله «قربانی اصلی» نامیده می‌شود، در حالی که سامانه‌های به خطر افتاده‌ای که برای اجرای حمله به کار می‌روند «قربانیان ثانویه» نام دارند [1]. با استفاده از قربانیان ثانویه، مهاجمان می‌توانند حملات بسیار بزرگ‌تر و مختل‌کننده‌تر انجام دهند و در عین حال ناشناس باقی بمانند، زیرا حمله توسط سامانه‌های به خطر افتاده اجراء شود. این امر ردیابی حمله را برای تحلیلگران شبکه بسیار دشوارتر می‌سازد.

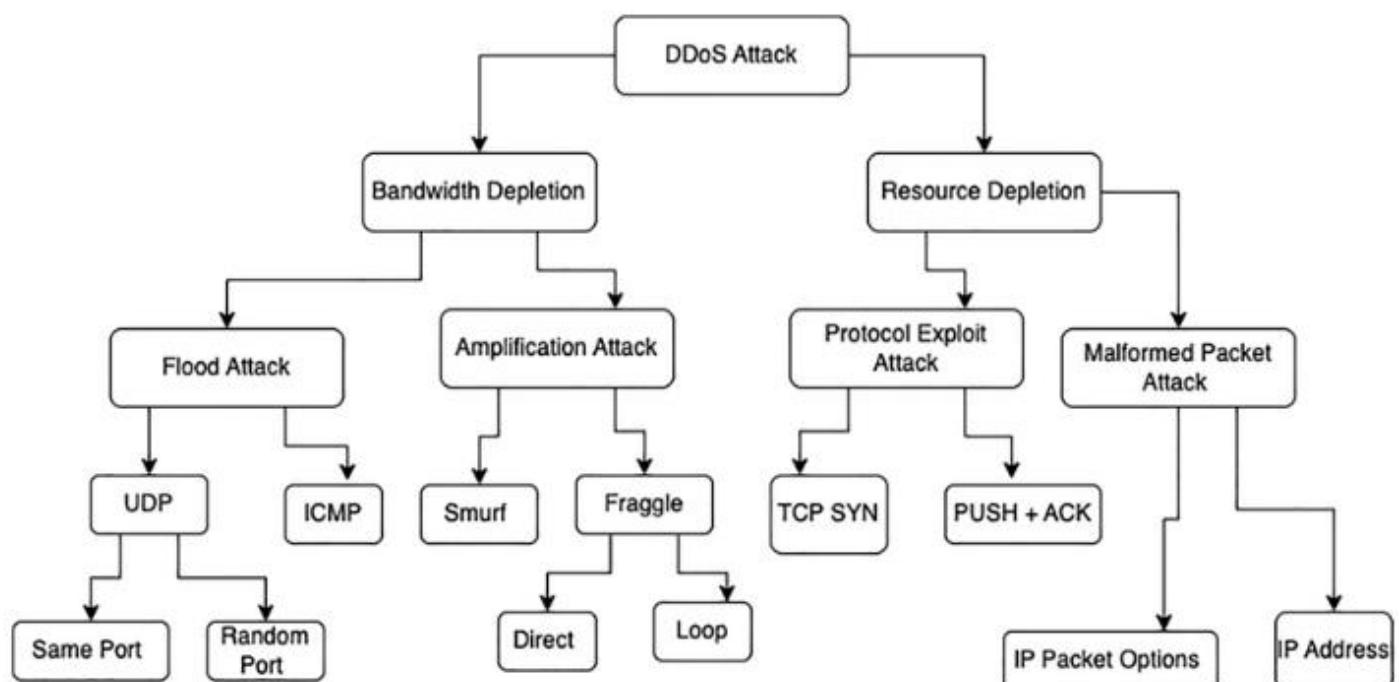
حملات DDoS به دلیل معمازی منحصر به فرد شبکه‌های SDN که صفحه کنترل را از صفحه داده جدا می‌کند، تأثیر عمیقی بر آن‌ها دارند [1]. در SDN، کنترل کننده مرکزی مؤلفه‌ای حیاتی است که مسئول مدیریت کل شبکه است. این مرکز بودن، کنترل کننده را به هدف اصلی برای حملات DDoS تبدیل می‌کند. اگر مهاجم بتواند کنترل کننده را با حجم بالای از درخواست‌ها غرق کند، می‌تواند منابع محاسباتی آن را تخلیه کرده و منجر به اختلالات جدی شبکه، حذف بسته‌ها و تأخیر در ترافیک قانونی شود. علاوه بر این، حملات DDoS می‌توانند از سازوکار تنظیم جریان در SDN سوءاستفاده کرده و با ایجاد تعداد زیادی درخواست جریان یکتا، موجب پرشدن جدول جریان در سوئیچ‌ها شوند. این سوئیچ‌ها که ظرفیت محدودی دارند، ممکن است شروع به حذف بسته‌ها یا کاهش کارایی کنند. آسیب‌پذیری دیگری نیز در API‌های شمالی و جنوبی وجود دارد که اگر به درستی ایمن‌سازی نشوند، می‌توانند برای ایجاد اختلال در ارتباط میان کنترل کننده و دستگاه‌های شبکه هدف قرار گیرند.



شکل ۱ معماری [1] SDN

شکل ۲ (در منبع [2]) ردیابی حملات DDoS را نشان می‌دهد که می‌توان آن‌ها را به طور کلی به دو دسته اصلی تقسیم کرد: حملات تخلیه پهنه‌ای باند و حملات تخلیه منابع. حملات تخلیه پهنه‌ای باند با هدف سیل آسا کردن شبکه قربانی با ترافیک ناخواسته انجام می‌شوند و اجازه نمی‌دهند که ترافیک قانونی به مقصد برسد. از سوی دیگر، حملات تخلیه منابع برای مصرف کامل منابع سامانه قربانی طراحی می‌شوند و باعث می‌گردند که سامانه نتواند درخواست‌های قانونی خدمات را پردازش کند. حملات تخلیه پهنه‌ای باند را می‌توان به حملات سیل آسا (Flood) و حملات تقویتی (Amplification) دسته‌بندی کرد. در حملات سیل آسا، حجم زیادی از ترافیک توسط دستگاه‌های به خطر افتاده (زمبی‌ها) به سامانه قربانی

ارسال می شود و موجب ازدحام پهنانی باند شبکه می گردد. این ازدحام می تواند باعث کندی، ازکارافتادگی یا اشباع پهنانی باند قربانی شده و دسترسی کاربران قانونی را مختل کند. حملات سیل آسامی توانند با استفاده از بسته های UDP (پروتکل دیتاگرام کاربر) و ICMP (پروتکل پیام کنترلی اینترنت) انجام شوند. در حمله UDP Flood ، تعداد زیادی بسته UDP به پورت های تصادفی یا مشخص شده در سامانه قربانی ارسال می شود. سامانه قربانی تلاش می کند داده های ورودی را پردازش کرده و مشخص کند کدام برنامه ها آن را درخواست کرده اند. اگر هیچ برنامه ای روی پورت هدف اجرا نشود، سامانه قربانی یک بسته ICMP با پیام «پورت مقصد در دسترس نیست» به فرستنده بازی گرداند. در حمله ICMP Flood ، دستگاه های به خطر افتاده حجم زیادی بسته ICMP_ECHO_REPLY («بینگ») به سامانه قربانی ارسال می کنند. این بسته ها قربانی را مجبور به پاسخ دادن می کنند و ترافیکی ترکیبی موجب ازدحام و اشباع پهنانی باند قربانی می شود. حملات تقویتی (Amplification) شامل ارسال پیام توسط مهاجم یا دستگاه های به خطر افتاده به یک آدرس IP پخشی (Broadcast) است که موجب می شود همه سامانه های درون زیر شبکه به سامانه قربانی پاسخ دهند. بیشتر روترهای از قابلیت پخش IP پشتیبانی می کنند؛ وقتی یک آدرس پخشی به عنوان مقصد تعیین شود، روتر بسته را تکثیر کرده و به تمام IP های موجود در دامنه پخش ارسال می کند. این سازوکار ترافیک حمله را تقویت و بازتاب می دهد و موجب اشباع پهنانی باند قربانی می شود. حمله Smurf نوعی حمله تقویتی است که در آن مهاجم بسته هایی را به یک تقویت کننده شبکه (سامانه ای که پخش آدرس را پشتیبانی می کند) ارسال می کند، در حالی که آدرس بازگشته جعل شده و روی IP قربانی تنظیم شده است. به طور مشابه، در حمله DDoS Fraggle ، مهاجم بسته های UDP ECHO را به یک تقویت کننده شبکه ارسال می کند. یک گونه دیگر از حمله Fraggle شامل ارسال بسته های UDP ECHO به پورتی است که تولید کاراکتر را پشتیبانی می کند chargen ، پورت ۱۹ در سیستم های یونیکس در حالی که آدرس بازگشته جعل شده و روی سرویس Echo (پورت ۷) تنظیم شده است، که یک حلقه بینهایت ایجاد می کند. بسته UDP Fraggle مولد کاراکتر سامانه های موجود در آدرس پخشی را هدف قرار می دهد. این سامانه ها کاراکتری تولید کرده و برای سرویس Echo قربانی می فرستند، و سرویس Echo نیز بسته کاراکتر برعی گرداند و این چرخه بی پایان ادامه می یابد. حملات تخلیه منابع در DDoS شامل ارسال بسته هایی است که از ارتباطات پروتکل های شبکه سوءاستفاده می کنند یا به صورت نادرست ساخته شده اند و منابع شبکه را اشغال کرده و هیچ منبعی برای کاربران قانونی باقی نمی گذارد.



شکل ۲ ردبهندی حملات [2]

حملات بهره برداری از پروتکل ها: دو نمونه شامل سوءاستفاده از پروتکل TCP SYN و پروتکل PUSH + ACK هستند. در یک حمله DDoS TCP SYN ، مهاجم به دستگاه های به خطر افتاده دستور می دهد درخواست های جعلی TCP SYN به سرور قربانی ارسال کنند و منابع پردازشی سرور را مشغول کرده و مانع پاسخ گویی آن به درخواست های قانونی شوند. در یک حمله PUSH + ACK ، عاملان حمله بسته های TCP را با بیت های PUSH و ACK که روی ۱ تنظیم شده اند ارسال می کنند. این تریگرها در سریرگ ها در TCP به سامانه قربانی دستور می دهند تمام داده های موجود در بافر TCP را (صرف نظر از اینکه بافر پر باشد یا نه) تخلیه کرده و پس از تکمیل، یک تأییدیه ارسال کنند.

حمله بسته معیوب زمانی رخ می دهد که مهاجم به دستگاههای به خطر افتاده دستور می دهد بسته های IP نادرست ساخت را به سامانه قربانی ارسال کنند تا آن را از کار بیندازند. حداقل نوع حمله بسته معیوب وجود دارد. در حمله آدرس IP، بسته شامل آدرس های IP مشابه برای مبدأ و مقصد است که می تواند سیستم عامل قربانی را سردرگم کرده و موجب ازکارافتادگی آن شود. در حمله گزینه های بسته IP، بسته معیوب ممکن است فیلدهای اختیاری درون بسته IP را تصادف سازی کرده و همه بیت های کیفیت خدمات را روی ۱ تنظیم کند که سامانه قربانی را مجبور می کند زمان پردازشی بیشتری برای تحلیل این ترافیک صرف کند. پژوهشگران چارچوبها و تکنیک های تشخیص و مقابله برای رسیدگی به حملات توسعه داده اند. پیشرفت سریع مدل های یادگیری ماشین نقش مهمی در افزایش دقت تشخیص و مقابله با حملات داشته است. مجموعه داده های باز، مجموعه هایی از داده های عمومی در دسترس هستند که آزادانه برای استفاده، بازنمایی و اصلاح بدون هیچ محدودیت قابل دسترسی می باشند. این مجموعه داده ها موضوعات گسترده ای را پوشش می دهند و اغلب توسط نهادهای دولتی، مؤسسات پژوهشی، سازمان های غیرانتفاعی و مشارکت کنندگان فردی ارائه می شوند. مجموعه داده های باز نقش مهمی در ترویج شفافیت، نوآوری و همکاری ایفا می کنند و منابع ارزشمندی برای پژوهش، تحلیل، توسعه کاربرد و آموزش فراهم می سازند. این مجموعه ها به عنوان بلوک های سازنده بنیادین برای مواجهه با چالش های اجتماعی، پیشبرد دانش علمی و ایجاد پیشرفت های فناورانه در حوزه های گوناگون به کار می روند. با استفاده از مجموعه داده های باز، پژوهشگران مدل ها را ارزیابی و تنظیم می کنند و از معیارهای ارزیابی عملکرد مانند دقت (precision)، فراخوان (recall) و F-measure برای سنجش کارایی مدل ها بهره می گیرند. اهداف این پژوهش شامل مجموعه داده های باز مربوط به حملات DDoS، انجام یک مرور تطبیقی بر SDN و بررسی تکنیک ها و چارچوب های تشخیص و مقابله با حملات توسعه شده در خدمات مختلف است. این بررسی چارچوبها و روش های رایج، دیدگاه های ارزشمندی درباره مزایا و محدودیت های رویکردهای موجود در اختیار پژوهشگران و متخصصان قرار می دهد و امکان توسعه راهبردهای دفاعی مقاومتر و آینده نگر را فراهم می سازد. علاوه بر این، تحلیل مجموعه داده های موجود، پژوهشگران و متخصصان را نسبت به داده های در دسترس خود آگاه تر کرده و توان بالقوه آن را برای بهره گیری در تحقیقات شان افزایش می دهد. این مطالعه به بررسی مجموعه داده های باز شامل نمونه های حملات DDoS می پردازد که در پژوهش های مختلف استفاده شده اند. برای مثال، وانگ و وانگ [3] یک تکنیک مقابله رديابي برای SDN ارائه کردند و برای توسعه و اعتبارسنجی روش خود به مجموعه داده های [4] InSDN و [5] CICIDS2017 متکی بودند. این مرور روش ها و چارچوب های گوناگون طراحی شده برای تشخیص و پیشگیری از حملات، به ویژه حملات DDoS، را بررسی می کند. از میان چارچوب های بر جسته بررسی شده در این پژوهش، Pro-Defense است که توسط Bawany و همکاران [6] توسعه یافته و بر کاربرد آن در شهرهای هوشمند تمرکز دارد. رویکردی مازولار اتخاذ می کند و اجزای گوناگون را برای افزایش کارایی آن ادغام می نماید. نقاط اصلی مشارکت این پژوهش، ارائه مجموعه به روز از تکنیک ها و چارچوب های مقابله با حملات SDN و نیز مروری جامع بر مجموعه داده های باز مربوط به این حملات و تکنیک ها و چارچوب های تشخیص و مقابله است. افزون بر این، این پژوهش مجموعه داده های در دسترس شامل نمونه های حملات DDoS را بر جسته می سازد. دوم اینکه با ارائه مروری جامع بر تکنیک ها و چارچوب های موجود برای تشخیص و مقابله، این مقاله نقطه شروع بسیار خوبی برای پژوهشگران فراهم می کند. همچنین نسخه به روزرسانی شده و گسترش تری از مجموعه داده های موجود نسبت به آنچه در Gebremariam و همکاران [7] ذکر شده ارائه می دهد. در نتیجه، این کار پژوهشگران را با مجموعه داده های به روز مجهز می کند تا دقت و مرتبط بودن آزمایش های شان افزایش یابد. جمع آوری و سازمان دهنده اطلاعات ضروری در این مقاله، روند پیشرفت پژوهشگران را تسهیل می کند، زیرا منبعی یکپارچه و کاربر پسند ارائه می دهد. با گردآوری و قالب بندی مناسب داده های لازم، پژوهشگران می توانند به راحتی به اطلاعات دسترسی یافته و از آن بهره بگیرند و در نهایت تحقیقات خود را در حوزه تشخیص و مقابله با حملات پیش ببرند.

باقی مانده این مقاله به صورت زیر سازمان دهنده شده است. بخش دوم به کارهای مرتبط با DDoS در SDN می پردازد. بخش سوم مروری دقیق بر مجموعه داده های باز ارائه می دهد که منبعی در دسترس بوده و بینش های ارزشمندی درباره حملات DDoS در SDN فراهم می کنند. بخش چهارم بر تکنیک ها و چارچوب های مقابله طراحی شده برای خنثی سازی حملات DDoS در SDN تمرکز دارد. بخش پنجم به بحث و تحلیل انتقادی یافته ها، پیامدها و مسیرهای بالقوه تحقیقات آینده می پردازد. در نهایت، بخش ششم مشارکت های پژوهش ما را خلاصه کرده و توصیه های برای کارهای آینده ارائه می دهد.

۲. مرور ادبیات

پژوهشگران مجموعه های از تکنیک ها و داده سرتها را برای رسیدگی به چالش های مختلف امنیتی بررسی کرده اند. برخی بر استفاده از یک داده است مشترک با تکنیک های متفاوت یادگیری ماشین تمرکز کرده اند، در حالی که دیگران داده سرت های مختلف را از سال های گوناگون بررسی کرده اند. این بخش این رویکردها را به تفصیل بررسی می کند و موضوعاتی مانند امنیت در شبکه های اینترنت اشیاء مدیریت شده توسعه SDN، تکنیک های تشخیص و کاهش حملات (DOS) و Denial-of-Service (DoS) با استفاده از SDN، به کارگیری یادگیری عمیق و یادگیری ماشین برای تشخیص و کاهش DDoS، سیستم های تشخیص نفوذ (IDS) با استفاده از XGBoost، و بهره گیری از هوش مصنوعی

و یادگیری ماشین برای امنیت SDN به طور کلی را پوشش می دهد. علاوه بر این، این بخش آسیب‌پذیری‌های امنیتی در شبکه‌های خودرویی ایمن شده با SDN را نیز بررسی می کند.

۲/۱ شبکه‌های اینترنت اشیاء مدیریت شده توسط SDN

ساریکا و همکاران [1] یک رویکرد خودکار و هوشمند برای تشخیص و کاهش نفوذ در SDN پیشنهاد کردند که هدف آن ارائه امنیت قابل توضیح در شبکه اینترنت اشیاء عصر 5G بود. رویکرد آنها از استخراج خودکار ویژگی‌های جریان و یک دسته‌بندی کننده جنگل تصادفی با دقت بالا برای طبقه‌بندی جریان شبکه در لایه کاربرد SDN استفاده کرد. این دسته‌بندی کننده قادر بود انواع مختلفی از حملات را تشخیص دهد و با نصب قواعد جریان جدید با اولویت بالا در صفحه داده، اقدامات اصلاحی انجام دهد. علاوه بر این، نویسنده‌گان یک داده‌ست ویژه SDN را معرفی کردند که یک محیط IoT واقعی را مدل سازی می کرد و شامل داده‌های جریان برای حملات رایج شبکه و ترافیک عادی بود. نتایج دقت تشخیص نفوذ و همچنین نتایج عملکرد سیستم با و بدون مکانیزم امنیتی پیشنهادی گزارش شد [1] اگرچه پژوهشگران یک مکانیزم امنیتی نویدبخش ارائه دادند، اما باید توجه داشت که سیستم تشخیص آنها عمدتاً در زمینه حملات DOS و DDoS ارزیابی شده بود. در نتیجه، داده‌ست استفاده شده ممکن است نماینده کافی برای انواع دیگر حملات مانند fuzzing و پویش پورت نباشد. همچنین، در آزمایش‌ها تنها یک میزبان مخرب برای تولید حملات استفاده شد که با سناریوهای واقعی، که در آن تهدیدها از منابع متعدد منشأ می‌گیرند، تفاوت دارد. با وجود این محدودیت‌های جزئی، مقاله به خوبی نوشه شده و داده‌ها را به صورت واضح و قابل فهم ارائه می کند.

ساریکا و همکاران [8] یک داده‌ست بدون عنوان برای تشخیص نفوذ در شبکه‌های IoT مدیریت شده توسط SDN تولید کردند. این داده‌ست‌ها شامل شبکه‌های IoT ایستا و پویا هستند و به ترتیب شامل 27.9 میلیون و 30.2 میلیون پورت، Open Network Operating System (ONOS) به عنوان کنترلر در این مطالعه استفاده شد، در حالی که ابزار hping3 برای ساخت بسته‌های TCP/IP جهت حملات DOS، Nmap برای پویش پورت و OS fingerprinting، Boofuzz برای fuzzing و OS fingerprinting 33 ویژگی است. تفاوت اصلی میان ویژگی‌ها تعداد دستگاه‌های IoT در شبکه است؛ به طوری که یکی از داده‌ست‌ها دارای پنج دستگاه IoT و دیگری دارای ۱۰ دستگاه IoT است. ترافیک سالم نیز از طریق تحلیل داده‌ست IoT bot به صورت خودتولیدی ایجاد شد، اما یک چالش قابل توجه، نبود نرم‌افزار متن باز برای این منظور بود.

کورونیوتیس و همکاران یک داده‌ست جدید با نام Bot-IoT معرفی کردند که شامل ترافیک معمول IoT و انواع مختلف ترافیک حمله رایج در باطن‌های بود [9]. داده‌ها با ویژگی‌های مربوط به جریان حمله، دسته‌بندی و زیردسته‌بندی برچسب‌گذاری شدند. معیارهای آماری مانند ضریب همبستگی و آنتروپی برای تعیین ۱۰ ویژگی برتر استفاده شد. برای ارزیابی کیفیت داده‌ست، پژوهشگران مدل‌های SVM، شبکه عصبی بازگشته (RNN)، و شبکه عصبی بازگشته حافظه کوتاه‌مدت (LSTM-RNN) را آموختند. چهار معیار—دقت، دقت پیش‌بینی، بازخوانی و نرخ خطای مثبت کاذب—برای سنجش کیفیت داده‌ست استفاده شد. نتایج نشان داد داده‌ست کامل هنگام آموختن با SVM بالاترین دقت و بازخوانی را به دست آورد، در حالی که داده‌ست ۱۰ ویژگی برتر بالاترین دقت پیش‌بینی و کمترین خطای مثبت کاذب را هنگام آموختن با SVM ارائه داد. با وجود اینکه این مطالعه بنیان ارزشمندی برای درک ترافیک حمله به دستگاه‌های IoT ایجاد کرد، محدودیت‌های نیز داشت. یک محدودیت کلیدی استفاده از تنها ۵٪ داده‌ست تولید شده برای آزمایش بود، که عمدتاً به دلیل چالش مدیریت ۷۲ میلیون رکورد بود. پژوهشگران به جای آن ۳ میلیون رکورد را برای مجموعه‌های آموخت و آزمایش انتخاب کردند که ممکن است خطاهای آماری مانند مثبت‌های کاذب ایجاد کند. علاوه بر این، گرچه روش‌های جمع‌آوری و پردازش داده برای یادگیری ماشین شرح داده شده بود، تکرار آن دشوار بود، تا حدی به دلیل منحنی یادگیری ابزارهایی مانند argus. همچنین برخی ابزارها که در ابتدا متن باز بودند، به مدل تجاری تغییر وضعیت داده بودند، مانند ostinato می‌تواند مانع برای تکرار پذیری ایجاد کند. پژوهشگران یک چارچوب تشخیص حملات DDoS مبتنی بر شمارنده با نام C-DAD برای شناسایی حملات DDoS ایجاد کردند [10]. این چارچوب با کنترلر SDNWISE ادغام شده و از شبیه‌ساز Cooja برای ایجاد یک محیط شبکه اینترنت اشیای نرم‌افزار محور (SD-IoT) استفاده می کند. یک راهکار دو بخشی برای شبکه‌های حسگر بی‌سیم است که هم یک چارچوب نرم‌افزاری مبتنی بر مفهوم شبکه‌های حسگر بی‌سیم نرم‌افزار محور (SD-WSN) و هم یک نمونه سخت‌افزاری واقعی برای تست و پیاده‌سازی نرم‌افزار ارائه می دهد. با تحلیل ترافیک IoT، چارچوب C-DAD می‌تواند حملات DDoS را با دقت بالا شناسایی کند. پژوهشگران سه آزمایش مختلف برای نشان دادن اثربخشی این چارچوب در شناسایی حملات انجام دادند. با وجود عملکرد قابل قبول چارچوب، یک محدودیت مهم آن این است که کنترلر IoT تنها در یک شبکه در محیط ناهمگون آزمایش شده و عملکرد آن در چندین شبکه IoT با شرایط متنوع بررسی نشده است. بین و همکاران [11] یک الگوریتم و چارچوب برای شناسایی و کاهش حملات SD-IoT در محیط SD-WSN ایجاد کردند. این چارچوب شامل مجموعه‌ای از کنترلرهای SDN، سویچ‌های SD-IoT همراه با دروازه‌های IoT و دستگاه‌های IoT است. الگوریتم با استفاده از شباهت کسینوسی بردارهای نرخ packet-in سویچ مرزی را با یکدیگر مقایسه می کند. پژوهشگران این چارچوب و الگوریتم را در یک محیط شبیه‌سازی SDN مبتنی بر Mininet آزمایش کردند که در آن نقش کنترلر را بر عهده داشت [11].

پژوهشگران در توسعه یک سیستم دفاعی پیش‌دستانه که بتواند حملات DDoS را در زمان واقعی شناسایی و خنثی کند، با چالش‌های روبرو بودند. علاوه بر این، آن‌ها توانزن بار بوسیله مجموعه کنترلرها پیاده‌سازی نکردند. توانزن بار، مکانیزی است که برای توزیع یکنواخت ترافیک شبکه یا بار کاری میان چندین کنترلر یا منبع طراحی می‌شود، و باعث بهبود استفاده از منابع و افزایش کارایی شبکه می‌گردد. در نهایت، شبیه‌سازی‌ها نشان دادند الگوریتم پیشنهادی می‌تواند منبع حمله DDoS را که از یک دستگاه IoT آغاز شده است، با دقت بالا شناسایی کند. این شناسایی سریع باعث تسريع فرآیند کاهش حمله شده و امنیت شبکه‌های IoT را که اغلب دارای قدرت پردازشی و حافظه محدود هستند، افزایش می‌دهد.

در جدول ۱، مروری بر اطلاعات داده‌ست، مزایا و معایب پژوهش‌های مربوط به شبکه‌های اینترنت اشیاء مدیریت‌شده توسط SDN ارائه شده است.

۲/۲ تشخیص و مقابله با حملات DoS و DDoS با استفاده از SDN

گالثانو-براخونس و همکاران [13] یک رویکرد Stateful مبتنی بر SDN برای شناسایی و کاهش حملات DoS و DDoS در شبکه‌های IoT توسعه دادند. آن‌ها از قابلیت Open vSwitch برای ایجاد ویژگی‌های Stateful روی یک سوییچ مجازی استفاده کردند. آزمایش‌ها در سه سناریو انجام شد:

- سناریوی اول: تحلیل مصرف پهنا برای باند در هنگام حمله DoS و فرایند مقابله، همراه با بررسی مقادیر آنتروپی. این سناریو به عنوان خط پایه عمل می‌کرد و از یک تست بد SDN شامل کنترلر Mininet و Ryu استفاده شد.
- سناریوهای دوم و سوم: استفاده از داده‌های IoT-Bot [12] برای ارزیابی فرایند تشخیص و مقابله با حملات DoS و DDoS در محیط IoT.

با وجود نتایج ارائه شده، مطالعه چند محدودیت داشت:

۱. تنها حملات DDoS مبتنی بر UDP بررسی شدند، که دید محدودی از عملکرد روش در برابر سایر بردارهای حمله ارائه می‌کند.
۲. در اندازه‌های پنجره بزرگ، برخی سوییچ‌ها نسبت به کنترلر پاسخ می‌شوند که می‌تواند قابلیت اجرایی سیستم را کاهش دهد.
۳. فرایند تشخیص می‌توانست با افزودن روش‌های آماری بیشتر یا مدل‌های یادگیری ماشین بهبود یابد.

یک رویکرد تشخیص دو مرحله‌ای در [14] ارائه شد تا امکان شناسایی زودهنگام حملات DDoS فراهم شود. این رویکرد شامل دو الگوریتم است که برای هر کاربر یک مقدار اعتماد (Trust Value) تعیین می‌کنند.

الگوریتم دو مرحله دارد:

- مرحله اول: استخراج فیلدهای هدر بسته‌های ورودی
- مرحله دوم: محاسبه مقدار اعتماد بر اساس اطلاعات استخراج شده

این مقدار اعتماد نقش اصلی در شناسایی مهاجمان احتمالی دارد. آزمایش با ابزارهای Wireshark، Mininet، Scapy و کنترلر POX انجام شد. با اینکه روش ارائه شده قوی است، یک چالش مهم باقی می‌ماند:

- تعیین آستانه مناسب برای تشخیص. آستانه کم → هشدار کاذب زیاد؛ آستانه زیاد → تشخیص پایین.
- حساسیت سیستم نیز وابسته به سطح اعتماد تعیین شده است که ممکن است فرایند تشخیص را پیچیده کند.

آسیس و همکاران [15] یک سیستم دفاعی برای شبکه‌های SDN پیشنهاد کردند که قادر است حملات DDoS را کنترل و سرورهای خارجی را با بازرسی ترافیک در بازه‌های یک‌ثانیه‌ای شناسایی و کاهش دهد. مدل تشخیص آن‌ها از شبکه عصبی کانولوشنی (CNN) استفاده می‌کند و با سه روش دیگر مقایسه شد: رگرسیون لجستیک (LR)، Dense-MLP و MLP.

روش‌ها در دو سناریو ارزیابی شدند:

- سناریوی اول: داده شبیه‌سازی شده SDN با Floodlight و Mininet
- سناریوی دوم: استفاده از داده‌ست عمومی CICDDoS2019 [16] که شامل بیش از ۱۲ نوع حمله DDoS است

نتایج نشان داد روش CNN:

- بالاترین دقت، بیشترین Precision و F-measure
- کمترین نرخ مثبت کاذب
- را به دست آورده است.

جدول ۱: خلاصه‌ای از اطلاعات مجموعه‌داده‌ها، مزایا و معایب شبکه‌های اینترنت اشیاء مدیریت شده توسط SDN

SARİKA و همکاران [1]، مجموعه‌داده [8]

مزیت: طبقه‌بند قادر بود انواع مختلف از حملات را شناسایی کند و با نصب قوانین جریان جدید با اولویت بالا در صفحه داده، اقدامات اصلاحی انجام دهد.

عیب: مجموعه‌داده استفاده شده ممکن است انواع دیگر حملات را به‌طور کافی پوشش ندهد. آزمایش‌ها تنها شامل یک میزبان مخرب بودند که حمله را ایجاد می‌کرد، که با سناریوهای واقعی که در آن تهدیدها از منابع متعدد سرچشمه می‌گیرند، متفاوت است.

SARİKA و همکاران [8]، مجموعه‌داده [8]

مزیت: مجموعه‌داده‌ها شامل شبکه‌های IoT ایستا و پویا هستند.

عیب: یک چالش قابل توجه، عدم دسترسی به نرم‌افزار متن‌باز برای این منظور بود.

کورونیوتیپس و همکاران [9] [12]

مزیت: پژوهش روش‌های جمع‌آوری و پردازش داده برای یادگیری ماشین را به تفصیل توضیح داده است.

عیب: تکرار فرایند دشوار بود.

بهیو و همکاران [10]، بدون مجموعه‌داده

مزیت: چارچوب به‌طور مؤثر عمل می‌کند.

عیب: عملکرد آن در چندین شبکه IoT در محیط‌های ناهمگون نشان داده نشده است.

بین و همکاران [11]، بدون مجموعه‌داده

مزیت: این شناسایی سریع، امکان کاهش حمله را سریع‌تر فراهم کرده و امنیت شبکه‌های آسیب‌پذیر IoT را بهبود می‌دهد.
عیب: این شبکه‌ها اغلب به دلیل توان پردازشی و حافظه محدود دستگاه‌های پایانی با محدودیت مواجه‌اند.

روش‌های MLP و D-MLP در شاخص Recall عملکرد بهتری داشتند. پژوهشگران همچنین یک مازول کاهش حمله معرفی کرده و یک رویکرد نظریه‌بازی را به عنوان نمونهٔ نحوه عملکرد آن ارائه کردند. روش مبتنی بر نظریه‌بازی، نرخ دورریزی بسته‌ها را در سیاست به کاررفته در کنترلر مرکزی SDN افزایش می‌دهد و مشخص شد که در بازیابی عملکرد عادی SDN موفق بوده است. با وجود موفقیت مازول تشخیص، این تحقیق محدودیت‌های نیز دارد. یکی از محدودیت‌های اصلی استفاده از تعداد کمی میزبان در مرحله آزمایش بود؛ افزایش تعداد میزبان‌ها می‌تواند تشخیص

حملات DDoS را دشوارتر و پنهان‌تر کند. محدودیت دیگر، استفاده نسبتاً محدود از تکنیک‌های یادگیری ماشین در مژول تشخیص است که می‌توانست برای افزایش کارایی، گسترده‌تر شود.

کیانی و همکاران [17] الگوریتمی برای شناسایی ناهنجاری‌ها در SDN ارائه کردند. یکی از الگوریتم‌ها بر تشخیص ناهماهنگی‌های متمرکز در جدول جریان تمکز داشت و دیگری برای شناسایی ناهنجاری‌های توزیع شده در میان چندین سوییچ شبکه طراحی شده بود. عملکرد این الگوریتم‌ها با استفاده از Mininet و کنترلر Ryu ارزیابی شد و مشخص شد که در شناسایی ناهنجاری‌ها مؤثر هستند. تنها محدودیت مشاهده شده این بود که فرایند تشخیص در مسیرهای طولانی‌تر زمان بیشتری نیاز داشت. یکی از نکاتی که پژوهشگران به آن اشاره کردند این است که افزایش تعداد قوانین در جدول جریان باعث ارسال مسیرهای طولانی‌تر به الگوریتم می‌شود، که در نتیجه زمان تشخیص ناهنجاری را افزایش می‌دهد. با این حال، الگوریتم توانست همه ناهنجاری‌ها را در محیط آزمایش شامل ۳۰ سوییچ و ۱۰۰ میزبان با موفقیت شناسایی کند.

روشی برای کاهش حملات traceback در شبکه‌های SDN توسط وانگ و همکاران [3] توسعه یافت. به فرایند شناسایی منبع ترافیک یا فعالیت‌های مخرب در شبکه اشاره دارد و شامل ردیابی مسیر بسته‌ها از مقصد به مبدأ است. نویسنده‌گان از ۱۰ ویژگی برای ردیابی منبع حمله DDoS اجراشده با hping3 استفاده کردند. علاوه بر این، یک مدل یادگیری عمیق ترکیبی به نام CNN-ELM (CNN) و ماشین یادگیری اکستریم (ELM) را ترکیب می‌کنند، برای تشخیص دقیق ناهنجاری پیشنهاد شد. این مدل با استفاده از مجموعه داده‌های InSDN-2017 [5] آزمایش شد. مجموعه داده CICIDS-2017 دقت ۹۸.۹۲٪ و مجموعه داده InSDN دقت ۹۹.۹۱٪ را نشان داد. یکی از معایب قابل توجه این روش، وابستگی آن به یادگیری نظارت شده است که به داده برجسب‌خورده فراوان نیاز دارد. پژوهشگران قصد دارند در آینده این چالش را با به کارگیری شبکه‌های عصبی گرافی بطرف کنند.

یک سازوکار امنیتی توسط نویسنده‌گان SDIoT-DDoS-DA برای شناسایی و کاهش حملات DDoS در شبکه‌های SDN پیشنهاد شد [18]. این سیستم با استفاده از چارچوب ONOS و کنترلر SDN-Wise پیاده‌سازی شد. برای ایجاد ترافیک DDoS از ابزار Trinoo استفاده شد و عملکرد سیستم روی مجموعه داده‌ای شامل ۱۰۵۴ درخواست آزمایش شد. ابزاری مشهور است که در بسیاری از حملات گذشته علیه وبسایت‌های بزرگ استفاده شده و ترافیک DDoS را با ارسال سیل‌آسای بسته‌های UDP تولید می‌کند، در حالی که ارتباط بین مهاجم و برنامه کنترل مرکزی با TCP برقرار می‌شود. یکی از محدودیت‌های مهم این مطالعه، کوچک بودن اندازه آزمایش (تنها ۱۰۵۴ درخواست) بود که می‌تواند بر دقت نتایج تأثیر بگذارد. نتایج شبیه‌سازی نشان داد سیستم تشخیص، ۸۷۶ درخواست را به عنوان «دسترسی غیرقانونی» طبقه‌بندی کرده است. در این مجموعه داده، ۱۱ درخواست به اشتباہ به عنوان مثبت کاذب شناسایی شدند. مژول تشخیص همچنین ۱۷۸ درخواست را درست به عنوان «دسترسی مشروع» طبقه‌بندی کرد، اما ۳۲ منفی کاذب نیز تولید نمود که نشان‌دهنده نیاز به بهبود بیشتر بخش تشخیص است.

بوانی و همکاران [6] یک چارچوب مژولار به نام ProDefence برای تشخیص و مقابله با حملات DDoS در یک شبکه گسترده، از جمله یک شهر هوشمند مبتنی بر زیرساخت SDN، توسعه دادند. این چارچوب شامل چندین مؤلفه است، مانند جمع‌آورنده جریان ترافیک، موتور سیاست‌گذاری، تشخیص‌دهنده حمله و موتور مقابله ProDefence. این مزیت را دارد که معیارهای سفارشی برای تشخیص حملات DDoS ارائه می‌دهد و در عین حال از توازن بار پشتیبانی می‌کند و با استفاده از یک پلتفرم کنترلر توسعه شده، خطر خرابی کنترلر را کاهش می‌دهد. ProDefence در محیط‌هایی با کنترلرهای ناسازگار با چالش‌هایی روبرو است. اتکای سیستم به Node.js برای یکپارچگی ممکن است هنگام استقرار سریع قوانین شبکه مشکل ایجاد کند. علاوه بر این، اگرچه ProDefence ادعا می‌کند با هر زیان برنامه‌نویسی سازگار است، این انعطاف‌پذیری نیازمند بررسی بیشتری است تا از عملکرد سازگار آن در محیط‌های اسکریپت‌نویسی مختلف اطمینان حاصل شود.

پژوهشگران OpCloudSec را طراحی کردند، یک سیستم از یک شبکه مبتنی بر تشخیص ناهنجاری است [19]. این سیستم از باور عمیق (DBN) برای ساخت مدل پیشگیری از حمله استفاده می‌کند. برای آزمایش، از دیتاست ISCX UNB استفاده شد. مدل حمله، دقت بیشتری نسبت به طبقه‌بندی‌های SVM، نقشه خودسازمانده (SOM) و NB نشان داد. این مطالعه توانایی سیستم را در ارتقای امنیت، در عین ایجاد حداقل اختلال در شبکه، توصیف می‌کند. با این حال، از آنجا که دیتاست ISCX UNB در یک محیط SDN تولید نشده است، ممکن است همان سطح دقیقی را که یک دیتاست اختصاصی SDN برای اعتبارسنجی سیستم فراهم می‌کند، ارائه ندهد. آزمایش‌های بیشتر با یک دیتاست ویژه SDN لازم است.

سینگ و همکاران [21] حدود ۷۰٪ مقاله بر جسته را بررسی کردند. آنها دریافتند که حدود ۴۷٪ از مطالعات از روش‌های مبتنی بر نظریه اطلاعات، حدود ۴۲٪ از روش‌های مبتنی بر یادگیری ماشین و تقریباً ۲۰٪ از روش‌های مبتنی بر شبکه‌های عصبی مصنوعی برای تشخیص حملات DDoS در SDN استفاده کردند. کنترلر همچنان هدف اصلی مهاجمان است، زیرا حیاتی‌ترین مؤلفه شبکه فعال شده توسط SDN محسوب می‌شود. چندین چالش پژوهشی همچنان وجود دارد، از جمله پذیرش معماری SDN، عدم وجود کنترلرهای سطح تولید، مشکلات مقایس پذیری، نگرانی‌های

امنیتی درباره سویچ‌های ارتباطی، و لینک‌های ارتباطی، و وابستگی به یک کنترلر مرکزی. این چالش‌ها پیاده‌سازی یک SDN ایمن را دشوار کرده و آن را به یک مسئله باز تبدیل می‌کنند.

سینگ و همکاران [22] طبقه‌بندی‌ای از آسیب‌پذیری‌های امنیتی موجود در معماری SDN ارائه می‌دهند که می‌تواند توسط حملات DDoS مبتنی بر جریان‌های جدید مورد سوءاستفاده قرار گیرد. آن‌ها تحلیلی از جدیدترین پیشرفت‌ها در پژوهش‌های شناسایی و مقابله با DDoS ارائه کرده‌اند که با هدف رفع این آسیب‌پذیری‌های امنیتی انجام شده است. همچنین، آن‌ها چالش‌های پژوهشی مرتبط با امنیت SDN را بررسی می‌کنند که می‌تواند برای جامعه پژوهشی و دانشگاهیان در تحقیقات آینده ارزشمند باشد. این مرور، طبقه‌بندی‌ای از مسائل امنیتی موجود در معماری SDN مرتبط با حملات DDoS مبتنی بر جریان‌های جدید ارائه می‌دهد. با تمرکز بر مشکلات امنیتی ذاتی، آن‌ها یک رده‌بندی از آسیب‌پذیری‌های اصلی طراحی در معماری SDN ایجاد کرند که به مهاجمان اجازه می‌دهد حملات مبتنی بر جریان‌های جدید را آغاز کنند. این طبقه‌بندی یک دیدگاه سلسه‌مراتبی روش از آسیب‌پذیری‌های بالقوه‌ای که می‌توان در معماری SDN از آن‌ها بهره‌برداری کرد، ارائه می‌دهد. این چارچوب به جامعه تحقیقاتی کمک می‌کند تا با درک ابعاد، وابستگی‌ها و تأثیرات مشکلات حملات DDoS، راهکارهای مؤثر دفاعی را شناسایی کنند. علاوه بر این، آن‌ها یک مرور جامع از راهکارهای دفاعی ارائه می‌دهند که شامل جدیدترین پیشرفت‌ها و تکنیک‌های مورد استفاده در محیط SDN است. پژوهشگران دلایلی برای روش‌های شناسایی DDoS مطرح می‌کنند تا بینشی درباره استراتژی‌های نوینی که طی سال‌های اخیر توسعه یافته‌اند، ارائه دهند و نشان دهند که چگونه الگوهای حملات DDoS تکامل یافته‌اند. در نهایت، آن‌ها چند پرسش چالش‌برانگیز پژوهشی مرتبط با امنیت SDN را که همچنان بدون پاسخ باقی مانده‌اند، بررسی می‌کنند.

جدول 2 نمای کلی از اطلاعات دیتاست‌ها، مزایا و معایب مرتبط با شناسایی و مقابله DOS و DDoS با استفاده از SDN ارائه می‌دهد.

2.3 روش‌های یادگیری عمیق و یادگیری ماشین برای شناسایی و مقابله با DDoS

در یک چارچوب پیشنهادی در [23]، از شبکه LSTM برای شناسایی حملات DDoS در سمت منبع شبکه استفاده شده است. این چارچوب با هدف رسیدگی به کاهش عملکرد ناشی از الگوهای غیرقابل پیش‌بینی ترافیک شبکه طراحی شده و با اعمال آستانه‌های تطبیقی مبتنی بر LSTM برای هر شبکه در سمت منبع عمل می‌کند. علاوه بر این، چارچوب یک شبکه همکاری شامل چندین نقطه تشخیص ایجاد می‌کند تا بازخورددهای مانند الگوهای ترافیک محلی، نرخ‌های شناسایی و زمان‌سنج‌ها را از هر نقطه جمع‌آوری کند. برای ارزیابی عملکرد این چارچوب، از ترافیک واقعی درخواست‌های DNS-STAT: Hedgehog جمع‌آوری شده از ICANN متعلق به DNS-STAT: Hedgehog استفاده شد [23].

یک محدودیت این مطالعه، امکان بهبود روش تشخیص سمت منبع از طریق استفاده از dynamic seasonality embedding است؛ رویکردی که با تحلیل و سازگاری با الگوها و روندهای در حال تغییر داده‌ها می‌تواند دقیق‌تر تباشد. علاوه بر این، فرآیند تشخیص می‌تواند با انتخاب هوشمندانه‌تر دستگاه‌هایی که در سیستم همکاری می‌کنند، بهبود یابد. راوی و همکاران [24] رویکرد LEDEM را برای شناسایی حملات DDoS با استفاده از یک الگوریتم نیمه‌نظری یادگیری ماشین پیشنهاد کردند. این رویکرد با استفاده از دیتاست [20] UNB-ISCX و یک testbed، همچنین تپیلوژی شبیه‌سازی شده در Mininet ارزیابی شد و با راهکارهای موجود مقایسه شد. نتایج نشان داد که LEDEM نرخ دقیق‌تر تشخیص حملات DDoS را تا ۹۶.۲۸٪ افزایش داده است. یک محدودیت قابل توجه در این پژوهش، اینکه یک تکنیک واحد یادگیری ماشین یعنی ELM است. این انتخاب به دلیل احتمال بروز false positive در هر دو روش نظری و بدون نظریت چالش‌برانگیز بود. پیدا کردن یک نیمه‌نظری است. این انتخاب که هم مدل فعلی را حفظ کند و هم بهبودهای واضحی ارائه دهد، مسئله‌ای دشوار است. سانتوس و همکاران [25]: در این مطالعه، الگوریتم‌های یادگیری ماشین شامل MLP، SVM، درخت تصمیم، و جنگل تصادفی برای شناسایی سه دسته حمله DDoS پیشنهاد شدند: حملات جدول جریان (flow-table) پهنه‌ای باند و حملات علیه کنترلرواین حملات با استفاده از ابزار Scapy و فهرستی شامل بیش از 20,000 آدرس IP به عنوان مهاجم تولید شدند و میزبان‌های متصل به شبکه SDN هدف قرار گرفتند، که در شبیه‌ساز Mininet VN با کنترل IPOX اجرا شده بود. نتایج آزمایشی نشان داد که الگوریتم درخت تصمیم به طور کلی بهترین عملکرد را به دلیل زمان پردازش کم داشت، اگرچه جنگل تصادفی بالاترین دقیق‌تر مطلق را کسب کرد.

جدول ۲: خلاصه‌ی اطلاعات دیتاست‌ها، مزایا و معایب مرتبط با شناسایی و مقابله DOS و DDoS با استفاده از SDN

Galeano-Brajones و همکاران 13, 12

- اطلاعات مجموعه‌داده Bot-IoT :
- مزایا: از قابلیت Open vSwitch برای ایجاد ویژگی‌های stateful بر روی یک استفاده کردن.

- معایب: از حملات UDP DDoS در آزمایش استفاده شد که دید محدودی از کارآمدی روش در مقابله با انواع مختلف DDoS ارائه می‌دهد.

و همکاران [14] – بدون مجموعه‌داده Salem

- اطلاعات مجموعه‌داده: ندارد
- مزایا: این روش برخلاف روش‌هایی است که بر یک مقدار آستانه ثابت و همواره متغیر تکیه می‌کنند.
- معایب: ایجاد تعادل در سیستم تعیین آستانه چالش‌برانگیز است.

و همکاران 15 – CICDDoS2019 Assis

- اطلاعات مجموعه‌داده CICDDoS2019 :
- مزایا: روش CNN بالاترین دقت و صحت را به دست آورد.
- معایب: تعداد محدود میزان‌ها در مرحله آزمایش مازول.

و همکاران [17] – بدون مجموعه‌داده Kiani

- اطلاعات مجموعه‌داده: ندارد
- مزایا: الگوریتم در تشخیص همه ناهنجاری‌ها در یک محیط آزمایشی شامل ۳۰ سوئیچ و ۱۰۰ میزان عملکرد مؤثری نشان داد.
- معایب: افزایش تعداد قوانین در جدول جریان موجب افزایش طول مسیرها می‌شود.

و همکاران 3 – InSDN Wang

- اطلاعات مجموعه‌داده InSDN CICIDS2017 :
- مزایا: مجموعه‌داده CICIDS2017 دقت ۹۸.۹۲٪ و مجموعه‌داده InSDN دقت بالاتر ۹۹.۹۱٪ را نشان داد.
- معایب: وابستگی به یادگیری نظارت شده.

و همکاران [18] – بدون مجموعه‌داده Wani

- اطلاعات مجموعه‌داده: ندارد
- مزایا: مازول تشخیص توانست ۱۷۸ فرمان را به عنوان درخواست‌های دسترسی مشروع طبقه‌بندی کند.
- معایب: سیستم برخی درخواست‌های مخرب را به اشتباه به عنوان benign (بی‌ضرر) تشخیص داد.

و همکاران [6] – بدون مجموعه‌داده Bawany

- اطلاعات مجموعه‌داده: ندارد
- مزایا: ProDefence: امکان تعریف معیارهای سفارشی برای تشخیص حملات DDoS را فراهم می‌کند.
- معایب: ادعای سازگاری با هر زبان برنامه‌نویسی نیازمند بررسی بیشتر است.

و همکاران 20 – UNB ISCX Sharma

- اطلاعات مجموعه‌داده UNB ISCX :
- مزایا: مدل حمله دقت بیشتری نسبت به SVM، GSOM و NB نشان داد.
- معایب: این مجموعه‌داده در یک محیط آزمایشی SDN تولید نشده است.

و همکاران [21] – بدون مجموعه‌داده Singh

- اطلاعات مجموعه‌داده: ندارد

• مزایا: بررسی حدود 70 مقاله برجسته پژوهشی.

• معایب: نبود کنترلرهای سطح تولید (Production-level controller).

Singh و همکاران [22] – بدون مجموعه داده

- اطلاعات مجموعه داده: ندارد
- مزایا: طبقه بندی پیشنهادی دیدی سلسله مراتبی و شفاف از آسیب پذیری های ارائه می دهد که ممکن است در معماری SDN مورد سوءاستفاده قرار گیرند.
- معایب: الگوهای حمله DDoS به مرور تکامل یافته اند و مقابله با آنها دشوار شده است.

Nadeem، محمد وقار و همکاران 26

این مقاله چندین روش مهم انتخاب ویژگی را برای یادگیری ماشین در زمینه تشخیص حملات DDoS ارزیابی می کند. انتخاب ویژگی های بهینه تأثیر قابل توجهی بر دقت طبقه بندی تکنیک های یادگیری ماشین و عملکرد کنترلر SDN دارد. پژوهشگران یک تحلیل مقایسه ای از روش های انتخاب ویژگی و طبقه بندی های یادگیری ماشین برای تشخیص حملات SDN ارائه می دهد که طبقه بند Random Forest (RF)، هنگامی که روی ویژگی های انتخاب شده با روش Recursive Feature Elimination (RFE) آموزش داده شود، به دقت بسیار بالای 99.97٪ دست می یابد. مجموعه داده NSL-KDD [27] برای آموزش و آزمون طبقه بندی های یادگیری ماشین در تشخیص حملات DDoS استفاده شد. سه روش فیلتر (IG)، Chi-Square و Correlation Coefficient (CC) برای انتخاب ویژگی های بهینه به کار رفتند. علاوه بر این، سه روش Backward Feature Selection (FFS)، Forward Feature Selection و wrapper-Forward Feature Selection (BFE) برای رتبه بندی ویژگی های بهینه استفاده شدند. الگوریتم انتخاب ویژگی Lasso نیز برای حذف کم اهمیت ترین ویژگی ها و تولید یک مجموعه ویژگی کاهش یافته به کار رفت. طبقه بندی های مانند SVM، KNN، NB و RRF نیز ارزیابی شدند. استخراج و انتخاب ویژگی های بهینه برای تشخیص دقیق حملات در مدل های یادگیری ماشین حیاتی است. نتایج آزمایش ها نشان می دهد که طبقه بند RF آموزش دیده با ویژگی های رتبه بندی شده توسط RFE عملکرد بسیار مناسبی در تشخیص حملات به کنترلر SDN دارد. با این حال، با افزایش مقیاس ترافیک شبکه، مصرف منابع کنترلر SDN افزایش یافته و دقت تشخیص کاهش می یابد. همچنین استفاده از ویژگی های نامربوط یا بیش از حد، بار کاری کنترلر را افزایش داده و ممکن است کارایی آن را تحت تأثیر قرار دهد.

Dehkordi و همکاران [28] این مقاله یک روش جدید برای تشخیص حملات DDoS در SDN ارائه می کند که شامل سه بخش اصلی است: بخش گردآورنده (collector)، بخش مبتنی بر آنتروپی، و بخش طبقه بندی. نتایج آزمایش با استفاده از مجموعه داده UNB-ISCX [20] و دیگر مجموعه داده ها نشان می دهد که این روش از نظر دقت عملکرد بهتری نسبت به روش های موجود دارد.

ارزیابی ها نشان داد که بخش های مبتنی بر آنتروپی با آستانه های ثابت، در مجموعه داده های مختلف نتایج رضایت بخشی ارائه نمی دهند. استفاده از آستانه های پویا نتایج بهتری ارائه کرد، اما نرخ مثبت کاذب (FPR) بالای ایجاد می کند. برای رفع این مشکل، انواع الگوریتم های طبقه بندی به کار گرفته شدند که نتایج دقیق تری تولید کردند. اهمیت این روش در دقت بالاتر آن نسبت به روش های مشابه است. با این حال، از آنجا که مدل ارائه شده بر یافتن راه حل پس از وقوع حمله تمرکز دارد، ارزیابی روش های پیشگیری از حملات DDoS در شبکه های SDN همچنان نیازمند بررسی بیشتر است. در این مطالعه از کنترلر Mininet 2.2.1 و Floodlight K=10 با مقدار K-fold برای شبکه استفاده شد. الگوریتم های طبقه بندی RandomTree، J48، Logistic Regression، BayesNet و REPTree همراه با روش BayesNet برای تشخیص حملات کم حجم استفاده شدند [29]. Perez-Diaz در این مقاله یک معماری مازولار و انعطاف پذیر برای شناسایی و مقابله با حملات DDoS کم نرخ (LR-DDoS) در محیط SDN ارائه شده است. سیستم تشخیص نفوذ (IDS) با استفاده از شش مدل یادگیری ماشین J48، CIC Dos [5]، Random Tree، REP Tree، Random Forest، MLP و SVM با استفاده از LR-DDoS ذاتا از مجموعه داده CIC Dos [5] ارزیابی شد. یافته ها نرخ تشخیص 95٪ را نشان می دهند، با وجود اینکه تشخیص حملات LR-DDoS از مجموعه داده CIC Dos [5] را بر روی یک ماشین مجازی Mininet مستقر کردن تا شرایط شبکه های واقعی را شبیه سازی کنند. ابزار دشوار است. آن ها کنترلر ONOS را با استفاده از مجازی Mininet می توانند تا شرایط شبکه های واقعی را شبیه سازی کنند. ابزار SlowHTTPTest برای اجرای حملات LR-DDoS از سمت مهاجمان به سرور وب مجازی استفاده شد و نتایج به گونه ای طراحی شد که به راحتی به محیط واقعی قابل انتقال باشد. سیستم جلوگیری از نفوذ (IPS) توانست تمامی حملات شناسایی شده توسط IDS را با موفقیت کاهش دهد. معماری امنیتی مازولار و انعطاف پذیر طراحی شده امکان جایگزینی هر مازول بدون تأثیرگذاری بر سایر بخش ها را فراهم می کند. اجریان ها را با استفاده از مدل های مختلف یادگیری ماشین که می توانند با زیان ها و چارچوب های متفاوت توسعه یابند، شناسایی می کند. ارزیابی شش الگوریتم یادگیری ماشین با استفاده از مجموعه داده CIC Dos (2017) دقت 95٪ را نشان داد. با استفاده از دو توپولوژی متفاوت، آن ها نشان دادند که تمامی حملات شناسایی شده توسط IDS به طور موفقیت آمیز کاهش داده شدند.

نویسنده‌گان در پژوهش [30] یک سامانه تشخیص نفوذ (IDS) برای شبکه‌های بین خودرویی VANET طراحی کردند و از مجموعه داده IoT-TON استفاده نمودند. برای بهبود کارایی و سرعت مدل، از تکنیک Chi-square استفاده شد که تعداد ویژگی‌ها را از ۳۱ به ۲۰ کاهش داد. تکنیک Chi² ابزاری ارزشمند در یادگیری ماشین برای انتخاب مرتبط‌ترین ویژگی‌ها از یک مجموعه داده است. این روش آماری با محاسبه نمره‌ای مبتنی بر میزان وابستگی هر ویژگی به متغیر هدف (برچسب‌های کلاس) عمل می‌کند. از این طریق می‌توان ویژگی‌هایی را که تأثیر اندکی بر پیش‌بینی خروجی دارند شناسایی و حذف کرد. با تمرکز بر ویژگی‌های مهمتر، تکنیک Chi² باعث افزایش کارایی و دقت مدل‌های یادگیری ماشین می‌شود. برای مقابله با بیش‌برازش (Overfitting) و سوگیری نسبت به کلاس اکثریت، از روش ISMOTE استفاده شد. این روش با ایجاد نمونه‌های مصنوعی از کلاس اقلیت، مشکل عدم توازن داده را برطرف کرده و عملکرد مدل را بهبود می‌بخشد.

جدول ۳: خلاصه اطلاعات مجموعه داده، مزایا و معایب روش‌های یادگیری عمیق و یادگیری ماشین برای تشخیص و مقابله

یئوم و همکاران [23] — بدون مجموعه داده — ترافیک واقعی درخواست‌های DNS جمع‌آوری شده از DNS-STAT: Hedgehog ، تحت مدیریت ICANN — امکان بهبود در روش تشخیص حمله از سمت منبع

راوی و همکاران 24 — UNB ISCX [20] — [نتایج نشان داد روش LEDEM دقت تشخیص حملات DDoS را تا ۹۶,۲۸٪ افزایش داده است — احتمال بروز مثبت‌های کاذب در روش‌های نظارت شده و بدون نظارت

سانتوس و همکاران [25] — بدون مجموعه داده — الگوریتم Random Forest بالاترین دقت را به دست آورد — الگوریتم Decision Tree به دلیل زمان پردازش پایین، بهترین عملکرد کلی را داشت

ندیم و همکاران 26 — NSL-KDD [27] — [طبقه‌بند RF آموخته دیده با ویژگی‌های انتخاب شده توسط RFE نتایج بسیار دقیقی در تشخیص حملات روی کنترل SDN ارائه داد — مصرف منابع کنترلر SDN افزایش می‌یابد و دقت با افزایش ترافیک کاهش پیدا می‌کند دهکردی و همکاران 28 — UNB ISCX [20] — [به کارگیری الگوریتم‌های مختلف طبقه‌بندی نتایج دقیق‌تری ایجاد کرد — نتایج بهتر با آستانه‌های پویا حاصل شد، اما با نرخ بالای مثبت کاذب (FPR)]

پرز-دیاز و همکاران 29 — CICIDS2017 [5] — همه حملاتی که توسط IDS شناسایی شدند با موفقیت مهار شدند — دشواری ذاتی در تشخیص حملات کمنخ (LR-DDoS)

مشکل عدم توازن داده‌ها مطرح است. برای ارزیابی عملکرد مدل یادگیری ماشین، از معیارهای مختلفی مانند دقت (Accuracy)، دقت مثبت (Precision)، فراخوانی (Recall)، امتیاز F1، نرخ مثبت کاذب (FPR) و ماتریس سردرگمی استفاده شد. الگوریتم XGBoost بالاترین عملکرد را در میان الگوریتم‌های آزمایش شده نشان داد. این مقاله یک توضیح جامع از فرایند پردازش داده برای پیاده‌سازی تکنیک‌های یادگیری ماشین ارائه می‌دهد. استفاده از مجموعه داده IoT-TON نیازمند تلاش‌های پیش‌پردازشی گسترده بود. در آینده می‌توان از یک مجموعه داده جایگزین برای آزمایش سیستم استفاده کرد که می‌تواند مفید باشد.

در مرجع [32]، نویسنده‌گان یک سامانه تشخیص نفوذ (IDS) طراحی کردند که حملات را سریع شناسایی کرده و تصمیم‌گیری می‌کند. این سیستم از شبکه عصبی مصنوعی (ANN) استفاده کرده و با مجموعه داده UNSW-15 [33] برای ارزیابی کارایی آن تست شد. نتایج ارزیابی نشان داد روش پیشنهادی نرخ دقت ۸۴٪ برای شناسایی تهدیدات و نرخ مثبت کاذب ۸٪ دارد. قرار است IDS در یک کنترل کننده IoT ادغام شود تا میان داده‌های سالم و مخرب تمایز قائل شده و داده‌های مخرب را سریع حذف کند. در تحلیل مقایسه‌ای این سیستم، دو مجموعه داده متفاوت استفاده شد. یک آزمایش ایده‌آل باید از یک مجموعه داده یکسان برای تمام سیستم‌ها استفاده کند تا مقایسه منصفانه باشد. لازم به ذکر است که مجموعه داده [27] از جنبه‌های مختلف با UNSW-15 متفاوت است، از جمله اندازه کوچک‌تر، تعداد کمتر نمونه‌های حمله، تعداد شبکه‌های کمتر، و تکرار بیشتر در داده‌ها Cruz. و همکاران [34] روشی برای ایجاد یک مدل سبک وزن با سریار کم ارائه دادند که دقت ۹۳.۶٪ را به دست آورد. این مطالعه از XGBoost به عنوان مدل یادگیری ماشین استفاده کرده و آن را بر روی مجموعه داده [35] IoT-23 با تمرکز بر حملات تکرارسازی (Replication Attacks) آزمایش کرد. حمله تکرارسازی نوعی اقدام فریبکارانه است که در آن مهاجم با تقلید ترافیک مشروع تلاش می‌کند به سیستم دسترسی غیرمجاز پیدا کند. مدل مورد استفاده در این روش می‌تواند در یک راهکار میان افزار IoT برای مسدود کردن دسترسی دستگاه‌های مشکوک ادغام شود. یکی از بهبودهای احتمالی در این تحقیق می‌تواند ارزیابی قابلیت سازگاری مدل و عملکرد سیستم بر اساس مجموعه داده‌های مختلف باشد. علاوه بر این، مفید است که الگوریتم XGBoost با سایر تکنیک‌های یادگیری ماشین مانند جنگل تصادفی (Random Forest) یا مدل‌هایی که خود را در طول آموزش با داده‌ها تطبیق می‌دهند مقایسه شود.

جدول 4 نمای کلی از اطلاعات مجموعه‌داده، مزایا و معایب IDS مبتنی بر الگوریتم XGBoost را ارائه می‌دهد.

2.5 رویکردهای هوش مصنوعی و یادگیری ماشین در SDN

Gebremariam در پژوهش خود بینش‌های ارزشمندی درباره استفاده از هوش مصنوعی/یادگیری ماشین (AI/ML) در شبکه‌های SDN و مجازی‌سازی کارکردهای شبکه (NFV) ارائه می‌دهد و پیشرفت‌های مهم این حوزه و همچنین چالش‌های آینده را در [7] شناسایی می‌کند. او معتقد است که ادغام AI/ML می‌تواند به ایجاد شبکه‌های منجر شود که خودتطبیق‌پذیر و خودمدیریت‌شونده باشند. با این حال، محدودیت منابع شبکه و نبود مجموعه‌داده‌های در دسترس همچنان از موانع مهم تحقیقات در این حوزه هستند. این تحقیق چندین مفهوم بر جسته معرفی می‌کند. عملیات ابری نیازمند الگوریتم‌های کارآمد و پردازش لبه (Edge Computing) است تا وظایف پیچیده را با حداقل‌سازی مصرف انرژی مراکز داده انجام دهد. علاوه بر این، ذخیره‌سازی راهبردی داده‌ها در سراسر شبکه در برابر خرابی‌ها و حملات از داده محافظت کرده و یکپارچگی و تاب‌آوری آن را تضمین می‌کند Zhoe. یک چارچوب ایجاد کرد که تولید، استقرار و تنظیم دفاع پیش‌گیرانه برای IoT را خودکار می‌کند [36]. این تیم از انعطاف‌پذیری معماری SDN برای استقرار کارآمد سازوکارهای دفاعی استفاده کرد. این چارچوب مبتنی بر تکنیک‌های دفاع هدف متحرک (MTD) و فربیب سایبری است. این رویکرد قصد دارد مهاجمان را گمراه کرده و اختلالات سیستم را کاهش دهد. تیم در محیط آزمایش از کنترلر Ryu و شبیه‌ساز Mininet برای ایجاد زیرساخت SDN استفاده کرد. این چارچوب دو ضعف کلیدی دارد: آسیب‌پذیری در برابر حملات اتمام منابع؛ مهاجمانی با منابع زیاد می‌توانند سیستم را با انبوهی از درخواست‌ها از کار بیندازند. ناتوانی در تشخیص کاربران مشروع از افراد داخلی (Insiders)؛ این محدودیت باعث می‌شود چارچوب تنها در برابر تهدیدات خارجی مؤثر بوده و در برابر حملات داخلی آسیب‌پذیر باشد Sahoo. و همکاران [37] یک روش برای تشخیص و کاهش حملات DDoS ارائه کردند که از ترکیب مدل‌های یادگیری ماشین SVM، KPCA و بیزی (GA) و الگوریتم ژنتیک (GA) استفاده می‌کند. در این روش SVM: نقش طبقه‌بندی کننده را دارد، تحلیل مؤلفه‌های اصلی هسته‌ای (KPCA) و الگوریتم ژنتیک (GA) استفاده می‌کند. همچنین یکتابع هسته‌ای اصلاح شده به نام N-RBF برای کاهش تفاوت‌های بیزی (Noisy) استفاده شد. برای ارزیابی مدل، نویسنده‌گان از دو مجموعه‌داده، شامل [27] NSL-KDD و یک SDN testbed با کنترلر POX استفاده کردند. این بستر آزمایشی با Mininet ایجاد شد. این راهکار چند محدودیت دارد: این سیستم در تشخیص بسته‌های ICMP مشكل دارد، زیرا این بسته‌های در کلاس "smurf" طبقه‌بندی می‌شوند و تمایز میان ترافیک سالم و حمله سخت می‌شود. نگرانی‌های مقیاس‌پذیری وجود دارد؛ زیرا محیط آزمایشی تنها شامل یک کنترلر بود. هرچند عملکرد آن در این شرایط قابل قبول بود، اما کارایی آن در محیطی با چندین کنترلر نامشخص است Tan. چارچوبی برای شناسایی و جلوگیری از حملات DDoS توسعه دادند [38]. این چارچوب از یک مکانیزم تحریک (Trigger Mechanism) در صفحه داده برای تشخیص چنین حملاتی استفاده کرده و از الگوریتم یادگیری ماشین مبتنی بر KNN و K-Means بهره می‌برد.

جدول 4. خلاصه‌ای از اطلاعات مجموعه‌داده، مزایا و معایب سامانه تشخیص نفوذ (IDS) با استفاده از الگوریتم XGBoost

: GAD و همکاران 30 مجموعه‌داده [31]

مزیت: الگوریتم XGBoost بهترین عملکرد را در میان الگوریتم‌های آزمایش شده نشان داد.

عیب: استفاده از مجموعه‌داده IoT به فرایند پیش‌پردازش قابل توجهی نیاز داشت.

: Hanif و همکاران 32 مجموعه‌داده [27]

مزیت: روش پیشنهادی دارای دقت ۸۴٪ است.

عیب: برای مقایسه منصفانه، لازم است تمام سیستم‌ها از یک مجموعه‌داده یکسان استفاده کنند.

: Cruz و همکاران 34 مجموعه‌داده [35]

مزیت: مدل مورد استفاده می‌تواند در یک میان‌افزار IoT برای مسدودسازی دسترسی دستگاه‌های مشکوک ادغام شود.

عیب: مقایسه‌ای میان الگوریتم XGBoost و سایر تکنیک‌های یادگیری ماشین انجام نشده است.

در این چارچوب، از کنترلر SDN برای شناسایی جریان‌های مشکوک استفاده می‌شود. کارایی این چارچوب با استفاده از مجموعه‌داده NSL-KDD [27] و همچنین یک محیط SDN ساخته شده با Mininet کنترلر SDN ارزیابی شده است. پژوهشگران با چالش‌هایی مربوط به توان پردازشی کنترلر مواجه شدند، به‌ویژه هنگامی که بار شبکه برای مدیریت ترافیک گستردۀ افزایش پیدا کرد. قابلیت تشخیص حملات در این چارچوب تحت بارهای سنگین شبکه کاهش می‌یابد. با افزایش حجم داده‌ها، به‌خصوص در زمان اوج ترافیک، کنترلر دچار اضافه بار می‌شود. این فشار باعث کاهش توانایی کنترلر در تشخیص مؤثر حملات DDoS شده و در نتیجه آسیب‌پذیری شبکه افزایش یافته و ممکن است کیفیت ارائه خدمات در زمان‌های پرtraفیک کاهش یابد. چارچوب دیگری توسط Revathi و همکاران [39] ارائه شد که از یک ماشین بردار پشتیبان مبتنی بر حافظه مقیاس‌پذیر و گستته (DSM-SVM) برای پیش‌بینی و کاهش حملات DDoS در SDN استفاده می‌کند. برای ارزیابی الگوریتم، مجموعه‌داده KDD99 [40] و یک بستر آزمایشی SDN شامل Mininet و کنترلر RYU مورد استفاده قرار گرفت. براساس پژوهش انجام شده، نگرانی‌های درباره نسبت تقسیم داده‌های آموزشی و آزمایشی وجود دارد. یک نسبت تقسیم متعادل نقش مهمی در تعیین پذیری مناسب الگوریتم ایفا می‌کند. این موضوع توانایی چارچوب را در تشخیص و کاهش حملات افزایش می‌دهد. مطالعه همچنین کاربرد سیستم در خدمات آنلاین را بررسی کرده و اثربخشی آن را در جلوگیری و کاهش حملات نشان می‌دهد؛ که این موضوع به افزایش امنیت و قابلیت اطمینان در محیط‌های خدمات آنلاین می‌انجامد Fajar . روش‌های مختلف کاهش حملات DDoS که از منابع مختلف منشأ می‌گیرند را بررسی کرده است [41]. مسائل امنیتی مرتبط با SDN نیز مورد بررسی قرار گرفت. با وجود تلاش‌های مداوم جامعه امنیتی برای توسعه مکانیزم‌های مقابله با حملات DDoS، تکنیک‌های موجود با محدودیت‌های مواجه هستند. برای رفع این نقص‌ها و تقویت امنیت کلی SDN، نویسنده‌گان پیشنهاد می‌کنند از قابلیت‌های منحصر به‌فرد شبکه نرم‌افزار محور برای ایجاد یک راهبرد دفاعی قوی‌تر استفاده شود Elsayed [4]. و همکاران 4 یک مجموعه‌داده عمومی جدید به نام InSDN معرفی کردن که شامل 343,939 نمونه از ترافیک عادی و مخرب است. داده‌های عادی 68,424 نمونه و داده‌های مربوط به حملات 275,515 نمونه را تشکیل می‌دهند. این مجموعه‌داده همچنین دارای 83 ویژگی است. مجموعه‌داده شامل دسته‌های مختلف حملات مانند DDoS ، ، حملات وب، باتنت، حدس رمزعبور، پروب‌ها و سوءاستفاده‌ها است. نویسنده‌گان کارایی مجموعه‌داده را با استفاده از معیارهای مانند دقت، بازنخوانی، نمره F و زمان آموزش ارزیابی کردن. هنگامی که چهار مجموعه‌داده عمومی مقایسه شدن، الگوریتم AdaBoost بهترین عملکرد را نشان داد. برای ارزیابی کیفیت مجموعه‌داده، هشت الگوریتم یادگیری نظارت شده از جمله درخت تصمیم(DT)، جنگل تصادفی (RF)، AdaBoost ، KNN، بیز ساده (NB)، SVM با هسته خطی، RBF با هسته RBF ، و MLP استفاده شد AdaBoost . بالاترین امتیاز را کسب کرد و پس از آن DT و RF قرار گرفتند. این مقاله محدودیت‌های مهمی را نیز بیان کرده است. از جمله مهم‌ترین محدودیت‌ها، عدم توازن چشمگیر کلاس‌ها در مجموعه‌داده است که ممکن است منجر به افزایش نرخ هشدار کاذب و کاهش دقت ارزیابی شود. علاوه بر این، آزمایش‌ها تنها از یک کنترلر ONOS استفاده کردن که نمی‌تواند تنوع کنترلرهای SDN و مکانیسم‌های امنیتی مختلف را پوشش دهد. همچنین به دلیل محدودیت‌های سخت‌افزاری، تنها یک کنترلر در شبکه مورد استفاده قرار گرفت، که توانایی بازنمایی معماری‌های بزرگ سازمانی با چند کنترلر، چند سوییج و چند گره را محدود می‌کند.

Tan و همکاران [42] سازوکارهای تشخیص و دفاع در برابر حملات DDoS در SDN را با استفاده از قابلیت‌های SDN و الگوریتم‌های یادگیری ماشین تحلیل کردن. رویکرد آن‌ها شامل یک روش هدفمند برای تشخیص و دفاع در برابر حملات DDoS است که به‌طور خاص کنترلر SDN را هدف قرار می‌دهند. نتایج آزمایش‌ها نشان می‌دهد که روش پیشنهادی تشخیص عملکرد مثبتی دارد. علاوه بر این، سازوکار شروع تشخیص (Trigger Mechanism) قادر است جریان‌های غیرعادی را به‌طور مؤثر شناسایی کند، در حالی که منابع کنترلر نیز حفظ می‌شوند. این استراتژی دفاعی نیز حملات DDoS را به‌طور مؤثر کاهش می‌دهد. با این حال، تحت ترافیک وسیع تر شبکه، بار کنترلر افزایش یافته و کارایی تشخیص کاهش پیدا می‌کند. در این مطالعه از کنترلر ONOS و Mininet برای شبیه‌سازی محیط شبکه استفاده شد. ابزار Scapy برای ایجاد آدرس‌های IP مقصد تصادفی جهت شبیه‌سازی حملات DDoS روی صفحه کنترل استفاده شد. برای تشخیص حملات DDoS ، از یک الگوریتم ترکیبی- K-Means و KNN استفاده شد. همچنین برای ارزیابی عملکرد روش، مجموعه‌داده NSL-KDD [27] به کار گرفته شد. در نهایت، محققان K-Means ، KNN، و نسخه ترکیبی آن دو را با نتایج DPTCM-KNN و KD-Tree مقایسه کردند.

Ali و همکاران [43]

هدف این مرور نظام‌مند، شناسایی، ارزیابی و بررسی تلاش‌های اخیر در زمینه‌ی راهکارهای تشخیص حملات DDoS مبتنی بر یادگیری ماشین (ML) و یادگیری عمیق (DL) در شبکه‌های SDN است. برای این منظور، یک مرور نظام‌مند از مقالات منتشرشده که از روش‌های ML/DL برای شناسایی حملات DDoS در شبکه‌های SDN بین سال‌های 2018 تا اوایل نوامبر 2022 استفاده کرده‌اند، انجام شد. این جستجوی جامع شامل چندین کتابخانه دیجیتال از جمله IEEE ، ACM ، Springer و دیگر منابع، به همراه Google Scholar بود. پژوهشگران مطالعات مرتبط را تحلیل کرده و نتایج را در پنچ بخش اصلی دسته‌بندی کردند: انواع روش‌های تشخیص حملات DDoS در رویکردهای ML/DL روش‌شناسی‌ها، نقاط قوت و ضعف رویکردهای موجود مجموعه‌داده‌ها و انواع حملات استفاده شده در تحقیقات پیشین راهبردهای پیش‌پردازش، مقادیر ابرپارامترها، تنظیمات آزمایش و معیارهای ارزیابی مقایسه عملکرد مدل‌های بسیاری از مطالعات، نرخ دقت بالاتر از 99٪ را گزارش کرده‌اند. با این حال، از آنچه که اکثر این تحقیقات از تحلیل آفلاین داده استفاده کرده‌اند، ممکن است عملکرد واقعی مدل‌ها در محیط‌های عملیاتی یا تولیدی متفاوت باشد. همچنین استفاده از مجموعه‌داده‌ها و روش‌های ارزیابی متفاوت در مقالات موجود، مقایسه مستقیم نتایج آن‌ها را دشوار می‌کند.

این مقاله قابلیت‌ها و اثربخشی مدل‌های یادگیری عمیق، بهویژه LSTM و شبکه‌های عصبی کانولوشنی (CNN)، را در تشخیص و مقابله با حملات DDoS بررسی می‌کند. تمرکز این پژوهش بر حملات ICMP Flood، TCP و UDP علیه کنترلر SDN است. عملکرد این مدل‌ها بر اساس معیارهای مانند دقت، بازخوانی و نرخ منفی درست ارزیابی و با مدل‌های سنتی یادگیری ماشین مقایسه شد. همچنین مدت زمان لازم برای تشخیص و مقابله با حملات مورد بررسی قرار گرفت. نتایج نشان داد که الگوریتم RNN یک مدل مناسب و کارآمد برای تشخیص و کاهش حملات DDoS در کنترلر SDN است. این مدل به دقت 89.63٪ دست یافت که بهتر از مدل‌های خطی مانند Naive Bayes و SVM 86.85٪ بود. اگرچه الگوریتم KNN به دقت بالاتری 99.4٪ دست یافت، اما مدل پیشنهادی با ارائه یک تعادل خوب میان دقت و بازخوانی، گزینه مناسبی برای دسته‌بندی حملات DDoS محسوب می‌شود. پژوهشگران همچنین مشاهده کردند که نسبت تقسیم داده‌های آموزشی و آزمایشی تأثیر قابل توجهی بر عملکرد مدل‌های یادگیری عمیق دارد. نسبت 30/70 بهترین عملکرد را نسبت به نسبت‌های 80/20 و 40/60 ارائه کرد. برای تولید ترافیک، از ابزار hping3 استفاده شد که ترافیک عادی TCP، UDP و ICMP را میان دو نقطه شبکه شبیه‌سازی می‌کرد. مجموعه داده شامل 10,031 نمونه بود که 4,270٪ ترافیک خرب و 5,761٪ ترافیک عادی بودند. این داده‌ها برای ساخت مدل‌های طبقه‌بندی دودویی با الگوریتم‌های مختلف ML مانند KNN، SVC، Linear SVC، SVC، درخت تصمیم، جنگل تصادفی، گرادیان بوستینگ و انواع طبقه‌بندی‌های CNN (گاوی، برنولی و چندجمله‌ای)، و همچنین دو مدل اصلی یعنی RNN و Naive Bayes استفاده شدند.

2.6 حملات در شبکه‌های خودرویی با استفاده از SDN و موارد بیشتر

۷۶ و همکاران 45 یک پلتفرم برای شناسایی و کاهش حملات DDoS در شبکه‌های خودرویی مبتنی بر SDN توسعه دادند. این پلتفرم از یک تکنیک تشخیص مبتنی بر جدول جریان (Flow Table Detection) استفاده می‌کند. برای ارزیابی اثربخشی این پلتفرم، آن را بر روی مجموعه داده‌های DARPA 1999 [46]، DARPA 2000 [47] و CAIDA DDoS 2007 [48] مبتنی بر Mininet ایجاد شد که از کنترلر Floodlight استفاده می‌کرد. این پژوهش به مسئله بار اضافی وارد بر کنترلر SDN در اثر تعداد زیاد پیام‌های IN_PACKET می‌پردازد. روش پیشنهادی با بهره‌گیری از IN_PACKET به عنوان محرك پاسخ سریع‌تر، این مشکل را کاهش داد. علاوه بر این، این مطالعه از پروتکل‌های TCP و UDP در سناریوهای حمله DDoS استفاده کرد. همچنین یک روش انتخاب ویژگی مبتنی بر ضریب همبستگی برای افزایش کارایی تحلیل به کار گرفته شد Maity. و همکاران یک سیستم تشخیص DDoS مبتنی بر مدل سازی احتمالاتی توسعه دادند که از توزیع پرچم‌های TCP در کنترلر SDN به جای سرعت ترافیک استفاده می‌کند تا نرخ خطای منفی کاهش یابد. این سیستم با استفاده از مجموعه داده DARPA 2009 [49] ارزیابی شد و در یک محیط SDN با کمک Mininet و کنترلر Floodlight آزمایش گردید. پژوهشگران با محدودیت‌های مواجه شدند، از جمله نبود تنوع کافی در انواع ترافیک شبکه که برای آزمایش جامع سیستم لازم بود. همچنین، مقاومت سیستم در برابر حملات DDoS کمتر از حد انتظار بود. آنان ابراز داشتند که قصد دارند در آینده این سیستم را به سمت پیاده‌سازی بلاذرنگ در محیط‌های توزیع شده هدایت کنند. جدول 6 مروری بر اطلاعات مجموعه داده‌ها، مزایا و معایب مربوط به حملات در شبکه‌های خودرویی مبتنی بر SDN و موارد بیشتر ارائه می‌دهد. جدول 7 نمایی کلی از مطالعات پیشین شامل روش‌ها، مجموعه داده‌ها و نکات کلیدی ارائه می‌کند.

3. جمیوعه داده‌ها

مجموعه داده‌های باز یا قابل دسترس عمومی برای پیشرفت پژوهش در زمینه تشخیص و کاهش حملات در SDN اهمیت فراوانی دارند. این مجموعه داده‌ها به عنوان یک پایه مشترک عمل کرده، امکان ادامه تحقیقات و تکرار پذیری نتایج را فراهم می‌کنند. دسترس پذیری مجموعه داده‌های باز به محققان اجازه می‌دهد تا بک استاندارد مشترک برای ارزیابی کاربردها و سناریوهای مختلف ایجاد کنند. در میان مجموعه داده‌های موجود، آن‌هایی که به طور خاص بر حملات DDoS تمرکز دارند برای پیشرفت تحقیقات بسیار ارزشمند هستند.

[46] DARPA98 مجموعه داده 98 DARPA98 الگوهای رایج ترافیک را در یک وب‌سایت دولتی با صدھا کاربر و هزاران میزیان شبیه‌سازی می‌کند. هنگام ایجاد این مجموعه داده، بیش از 300 نمونه از 38 نوع حملة خودکار متفاوت تولید شده بود.

جدول ۵ خلاصه‌ای از اطلاعات مجموعه داده‌ها، مزایا و معایب رویکردهای هوش مصنوعی و یادگیری ماشین در SDN

4. Gebremariam و همکاران 7 بدون مجموعه داده

✓ ذخیره‌سازی راهبردی داده‌ها در سراسر شبکه از خرابی‌ها و حملات چلوگیری می‌کند و یکپارچگی و تاب‌آوری داده‌ها را تضمین می‌کند.
✗ منابع محدود شبکه و نبود مجموعه داده‌های آماده و در دسترس.

و همکاران 36 بدون مجموعه داده Zhou

- ✓ این روش با هدف گمراحت کردن مهاجمان و کاهش اختلالات سیستم طراحی شده است.
✗ مستعد حملات تخلیه منابع (Resource exhaustion).

و همکاران 37 Sahoo NSL-KDD [27]

- ✓ به عنوان دسته بند عمل می کند، در حالی که KPCA استخراج ویژگی ها را انجام می دهد و GA نیز SVM را بهینه می کند.
✗ در محیط هایی با چند کنترلر، عدم قطعیت هایی ایجاد می شود.

و همکاران 38 Tan NSL-KDD [27]

- ✓ کارایی این چارچوب با استفاده از مجموعه داده NSL-KDD و یک محیط SDN مبتنی بر Mininet ارزیابی شده است.
✗ کنترلر توانایی خود را در تشخیص مؤثر حملات DDoS از دست می دهد.

و همکاران 39 Revathi KDD99 [40]

- ✓ مطالعه همچنین به کاربرد این سیستم در خدمات آنلاین پرداخته و کارایی آن را در جلوگیری و کاهش حملات نشان می دهد.
✗ نگرانی هایی درباره نسبت تقسیم داده های آموزش و آزمون وجود دارد.

و همکاران 41 Fajar بدون مجموعه داده

- ✓ نویسنده ای پیشنهاد بهره گیری از قابلیت های منحصر به فرد SDN را برای یک راهبرد دفاعی قدرتمندتر مطرح می کنند.
✗ هیچ مورد منفی گزارش نشده است.

و همکاران 4 Elsayed InSDN [4]

- ✓ دسته بند AdaBoost بالاترین عملکرد را داشته و پس از آن DT و RF در رتبه های بعدی قرار دارند.
✗ این مجموعه داده تنها از یک کنترلر استفاده کرده است.

و همکاران 42 Tan NSL-KDD [27]

- ✓ آزمایش ها نشان می دهند روش های پیشنهادی تشخیص نتایج مثبتی ارائه می دهند.
✗ در ترافیک شبکه در مقیاس بزرگ، بار کنترلر افزایش یافته و کارایی تشخیص DDoS کاهش می یابد.

و همکاران 43 Ali بدون مجموعه داده

- ✓ بسیاری از مطالعات دقیق بالای ۹۹٪ را گزارش کرده اند.
✗ این مطالعات از تحلیل آفلاین استفاده کرده اند؛ بنابراین عملکرد در محیط واقعی ممکن است متفاوت باشد.

و همکاران 44 Gadze

بدون مجموعه داده

- ✓ نسبت تقسیم ۳۰/۷۰ بهترین عملکرد را نسبت به ۲۰/۸۰ و ۴۰/۶۰ ارائه داده است.
✗ نبود مجموعه داده باعث دشوار شدن تکرار پذیری نتایج می شود.

ترجمهٔ فارسی جدول ۶: خلاصه اطلاعات مجموعه‌داده، مزایا و معایب حملات در شبکه‌های خودرویی مبتنی بر SDN و سایر موارد

Yu et al. [45]

CAIDA DDoS 2007 [48], DARPA 99 [47], DARPA 2000 [50]

مزیت: این روش با بهره‌گیری از مکانیسم PACKET_IN trigger توانست این مشکل را به‌طور موفقیت‌آمیزی کاهش دهد و زمان واکنش را تسريع کند.

عیب: هیچ‌کدام گزارش نشده است.

Maity et al. [49]

DARPA 2009 [51]

مزیت: هیچ‌کدام گزارش نشده است.

عیب: مقاومت سیستم در برابر حملات DDOS کمتر از حد انتظار بود.

دارپا 98: [46]

در این مجموعه‌داده، الگوهای ترافیکی معمولی مربوط به یک وب‌سایت دولتی که صدھا کاربر در میان هزاران میزبان از آن استفاده می‌کنند، شبیه‌سازی شده است. طی فرآیند ایجاد این مجموعه‌داده، بیش از ۳۰۰ نمونه از ۳۸ نوع حمله خودکار مختلف علیه میزبان‌های مبتنی بر UNIX اجرا شد. آزمایشگاه لینکلن MIT این مجموعه‌داده را طی ۷ هفته و با حجم ۴ گیگابایت داده بازیگری تولید کرد. این مجموعه، سناریوی شبیه یک شبکه کوچک نیروی هوایی متصل به اینترنت را بازسازی می‌کند و به عنوان یک مرجع مهم برای ارزیابی سامانه‌های تشخیص نفوذ (IDS) مورد استفاده قرار می‌گیرد [9].

دارپا 99: [47]

این ارزیابی جامع، که منجر به تولید مجموعه‌داده DARPA 99 شد، هشت مرکز پژوهشی را در تحلیل توانایی تشخیص و نرخ هشدار اشتباہ سامانه‌های تشخیص نفوذ درگیر کرد. ارزیابی در یک محیط شبکه‌ای کنترل شده انجام شد که شامل میزبان‌هایی بود که در معرض حملات حملات می‌گرفتند و ترافیک مصنوعی ایجاد شده توسط مولدهای پیشرفت‌هایی را دریافت می‌کردند که رفتاری مشابه ترافیک زنده یک پایگاه کوچک نیروی هوایی داشتند. شبیه‌سازی ترافیک، رفتار صدھا کاربر و هزاران میزبان را تقلید می‌کرد. در طی ۳ هفته داده آموزش و ۲ هفته داده آزمون، بیش از ۲۰۰ نمونه از ۵۸ نوع حمله متفاوت علیه میزبان‌های UNIX و Windows NT اجرا شد. حاصل این فرایند، مجموعه‌داده ارزشمند DARPA 99 برای تحقیقات امنیت سایبری بود.

دارپا 2000: [50] (DARPA2000) در سال ۱۹۹۹، آزمایشگاه لینکلن مجموعه‌داده DARPA 2000 را معرفی کرد که شامل ۵ هفته ترافیک

شبیه‌سازی شده شبکه‌ای است. این مجموعه شامل دو سناریوی حمله است LLDOS 1.0 و LLDOS 2.0.2. هر دو سناریو از میزبان‌های حمله کننده و قربانی یکسان استفاده می‌کنند و شامل انواع حملات:

DoS	•
User-to-Root (U2R)	•
Remote-to-Local (R2L)	•
Probe	•
هستند.	

حملات در پنج مرحله انجام می‌شوند:

۱. اسکن میزبان، ۲. ارسال بسته‌های پرسش آسیب‌پذیری، ۳. سوءاستفاده و افزایش سطح دسترسی، ۴. نصب نرمافزار DDoS روی میزبان قربانی، ۵. اجرای حمله DDoS روی هدف.

دارپا 2009 [51]:2009

این مجموعه‌داده با استفاده از ترافیک مصنوعی شبیه‌سازی شد تا تعاملات میان یک زیرشبکه ۱۶/۰.۰.۰.۱۶ (دامنه ۱۷۲.۲۸.۰.۱۶) و اینترنت را بازنمایی کند. داده‌ها طی ۱۰ روز، از ۳ تا ۱۲ نوامبر ۲۰۰۹ جمع‌آوری شدند. این مجموعه شامل ترافیک مصنوعی DNS و SMTP، HTTP و دارای

طیف وسیعی از رویدادهای امنیتی و انواع حملات، از جمله حملات مختلف DDoS و انواع کرم‌ها (worms) با الگوهای گسترش متفاوت است. این مجموعه شامل ۷۰۰۰ فایل pcap بوده و حجم کل آن تقریباً ۵/۶ ترابایت است.

:KDD99 [40]

برای تهیه یک زیرمجموعه از داده‌های DARPA 1998 LAN نیروی هوایی آمریکا شبیه‌سازی شد و انواع مختلف حملات روی آن اجرا شد. این فرایند از ۹ هفته داده TCP dump جمع‌آوری شده در MIT Lincoln Lab استفاده کرد. نتیجه آن، مجموعه داده KDDCup است که شامل تقریباً ۴/۹ میلیون نمونه با ۴۱ ویژگی است. این نمونه‌ها به دو دسته «عادی» و «دارای نفوذ» تقسیم می‌شوند. داده آموزشی: شامل 24 برجسب (۱ رفتار عادی + ۲۳ نوع حمله) داده آزمون: شامل ۱۴ نوع حمله جدید اضافه شده

حملات در چهار گروه طبقه‌بندی می‌شوند Probe-R2L-DoS- U2R

:NSL-KDD [27]

این مجموعه پس از حذف داده‌های تکراری و افزونه‌های موجود در KDDCup ایجاد شد. داده‌ها شامل:

- 125,973 رکورد برای آموزش
- 22,544 رکورد برای آزمون
- در این مجموعه، از میان ۳۷ حمله: ۲۷ حمله در داده آزمون • ۲۳ حمله در داده آموزش
- قرار گرفته‌اند. این مجموعه مانند KDDCup، ۴۱ ویژگی و ۵ کلاس (۱ کلاس عادی + ۴ کلاس حمله) دارد و توزیع بهتری نسبت به KDD99 را کرائے می‌کند.

:DECON-8 [52]

نسخه 8 DEFCON شامل حملات مبتنی بر اسکن پورت و سریز بافر است. نسخه دیگر این مجموعه شامل حملات مبتنی بر FTP ، بسته‌های مخرب، اسکن پورت و حملات sweep است. با این حال، این مجموعه داده محدودیت دارد؛ زیرا ترافیک موجود در مسابقات «Capture the Flag (CTF)» با ترافیک واقعی شبکه تفاوت زیادی دارد و همین موضوع ارزیابی سامانه‌های IDS را تحت تأثیر قرار می‌دهد.

جدول ۷. خلاصه کارهای پیشین بر اساس روش‌ها، مجموعه داده‌های به کاررفته و نکات برجسته

1 Sarica و همکاران
روش طبقه‌بندی کنندگان Random Forest : SDN Dataset [8]

رویکرد آن‌ها بر استخراج خودکار ویژگی‌های جریان و طبقه‌بندی بسیار دقیق جریان‌های شبکه با استفاده از طبقه‌بندی کننده Random Forest در لایه کاربردی SDN متکی بود. این روش برای تشخیص انواع مختلف حملات و اقدامات اصلاحی از طریق نصب قوانین جریان جدید با اولویت بالا در سطح داده به کار گرفته شد.

13 Galeano-Brajones و همکاران
روش الگوریتم مبتنی بر آنتروپی : Bot-IoT [12]
مجموعه داده سه سناریو ارائه شد:

1. نمایش مصرف پهنای باند و مقادیر آنتروپی در طول یک حمله DoS و فرایند کاهش آن با استفاده از کنترلر Ryu و بستر آزمایشی Mininet.
2. دو سناریوی بعدی از مجموعه داده Bot-IoT برای ارزیابی فرایند تشخیص و کاهش حملات DoS در محیط IoT استفاده کردند.

3. سناریوی پایانی بر تشخیص و کاهش حملات DDoS در محیط IoT تمرکز داشت.

و همکاران 3 Wang

روش: مدل ترکیبی CNN-ELM و Extreme Learning Machine
مجموعه داده [4] : InSDN CICIDS2017 [5]

پژوهشگران یک روش کاهش حمله (traceback) برای شبکه های SDN ارائه کردند. آنها با استفاده از ده ویژگی توانستند مسیر منبع حمله را شناسایی کنند. همچنین یک مدل یادگیری عمیق ترکیبی CNN-ELM (شبکه عصبی کانولوشنی + ماشین یادگیری سریع) پیشنهاد شد.

و همکاران 19 Sharma

روش: شبکه باور عمیق (Deep Belief Network)
مجموعه داده [20] : UNB ISCX

پژوهشگران یک سیستم تشخیص و واکنش به حمله مبتنی بر ناهنجاری به نام OpCloudSec ایجاد کردند. این سیستم از DBN برای ایجاد مدل پیشگیری از حملات استفاده می کند.

و همکاران 14 Salem

روش: الگوریتم دو مرحله ای

مجموعه داده [20] : بدون مجموعه داده

آنها یک روش تشخیص دوبخشی با دو الگوریتم ارائه کردند تا تشخیص زودهنگام حملات DDoS امکان پذیر شود. این روش به هر کاربر یک مقدار اعتماد اختصاص می دهد و همراه با ارسال درخواست ها به کنترلر، تعداد درخواست ها ثبت و مستند می شود.

و همکاران 15 de Assis

روش: CNN

مجموعه داده [16] : CICDDoS2019

پژوهشگران یک سیستم دفاعی برای شبکه های SDN پیشنهاد دادند که ترافیک را در بازه های یک ثانیه ای بررسی می کند. سیستم، حملات DDoS به کنترلر و سرور خارجی را تشخیص و کاهش می دهد. همچنین مازول کاهش و یک نمونه رویکرد مبتنی بر نظریه بازی توضیح داده شد.

و همکاران 24 Ravi

روش: LEDEM

مجموعه داده [20] : UNB ISCX

آنها رویکرد جدیدی به نام LEDEM (تشخیص و کاهش مبتنی بر یادگیری) ارائه کردند که از یک الگوریتم نیمه ناظارتی برای تشخیص حملات DDoS استفاده می کند.

و همکاران 30 Gad

روش: XGBoost

مجموعه داده [31] : ToN-IoT

یک IDS برای VANET با استفاده از مجموعه داده ToN-IoT ساخته شد. برای بهبود سرعت و کارایی مدل، از روش انتخاب ویژگی Chi2 استفاده شد که ویژگی ها را به ۲۰ مورد کاهش داد.

و همکاران 32 Hanif

روش: شبکه عصبی مصنوعی (ANN)

مجموعه داده [27] : NSL-KDD

پژوهشگران یک IDS توسعه دادند که قادر به تشخیص حملات و اتخاذ تصمیم سریع است. این سیستم در کنترلر IoT ادغام می شود تا داده ورودی را به سالم یا مخرب طبقه بندی کند و داده مخرب را بلا فاصله حذف کند.

و همکاران 8 Wani

روش: SDIoT-DDoS-DA

مجموعه‌داده: بدون مجموعه‌داده
یک سازوکار امنیتی برای تشخیص و کاهش حملات DDoS در شبکه‌های SDN با نام SDIoT-DDoS-DA پیشنهاد شد.

Sahoo و همکاران [37]
روش SVM، PCA و GA : NSL-KDD [27]
مجموعه‌داده: یک روش برای تشخیص و کاهش حملات DDoS ارائه شد که از ترکیب SVM، تحلیل مؤلفه‌های اصلی هسته‌ای (KPCA)، والگوریتم زنتیک (GA) استفاده می‌کند.

در ادامه Table 7

Yu et al. [45]
تکنیک تشخیص جدول جریان
مجموعه‌داده‌ها: CAIDA DDoS 2007 [48]، DARPA 99 [47]، DARPA 2000 [50]
پژوهشگران یک پلتفرم برای شناسایی و مقابله با حملات DDoS در شبکه‌های خودرویی مبتنی بر SDN ایجاد کردند. این پلتفرم از یک تکنیک تشخیص جدول جریان استفاده می‌کرد.

Maity et al. [49]
احتمالاتی مدل [یک مجموعه‌داده]: DARPA 2009 [51]
یک تیم پژوهشی یک سیستم تشخیص DDoS مبتنی بر مدل سازی احتمالات طراحی کرد. این مدل به جای تکیه بر سرعت ترافیک، از توزیع پرچم‌های TCP در کنترلر برای کاهش نرخ منفی کاذب استفاده می‌کند.

Yeom et al. [23] LSTM مجموعه‌داده: بدون مجموعه‌داده

پژوهشگران یک چارچوب تشخیص حملات DDoS مبتنی بر LSTM پیشنهاد کردند که در سمت منبع عمل می‌کند. برای کاهش افت عملکرد ناشی از رفتار نامنظم ترافیک شبکه، این چارچوب از آستانه‌های تطبیقی مبتنی بر LSTM برای هر منبع شبکه استفاده می‌کند.

UNIBS [53]

تیریس‌های بسته UNIBS طی سه روز کاری پیاپی از روتور لبه شبکه دانشگاه برسیا در ایتالیا جمع‌آوری شدند. این مجموعه‌داده شامل ترافیکی است که از ۲۰ ایستگاه کاری که همه آن‌ها سرویس GT (Ground Truth) را اجرا می‌کردند، استخراج شده است. داده‌ها با استفاده از tcpdump از روتور دانشکده — یک سیستم لینوکسی دو پردازنده — Xeon که شبکه محلی را از طریق یک لینک اختصاصی ۱۰۰ مگابیت بر ثانیه به اینترنت متصل می‌کرد، جمع‌آوری شد. این مجموعه‌داده شامل ۲۷ گیگابایت داده و حدود ۷۹,۰۰۰ جریان است؛ عمدتاً ترافیک TCP ۹۹٪ و UDP ۱٪ ترافیک ثبت شده شامل وب (HTTP، HTTPS)، ایمیل (POP3، IMAP4)، SMTP و نسخه‌های SSL آنها، اسکایپ، برنامه‌های همتابه هم‌مانند eDonkey و BitTorrent، و سایر پروتکل‌ها مانند MSN و SSH است.

CAIDA DDoS 2007 [48]

این مجموعه‌داده شامل تیریس‌های ترافیکی است که در جریان حملات DDoS در سال ۲۰۰۷ ضبط شده‌اند. این حملات با ارسال حجم عظیمی از بسته‌های باعث اختلال در ترافیک طبیعی شبکه و جلوگیری از رسیدن درخواست‌های مشروع به مقصد می‌شوند. یکی از ضعف‌های این مجموعه‌داده، تنوع پایین حملات است. همچنین داده جمع‌آوری شده شامل ویژگی‌های جامع از کل شبکه نیست و این موضوع، تشخیص دقیق ترافیک عادی و غیرعادی را دشوار می‌کند.

LBNL [54]

این مجموعه داده شامل ترافیک ناشناس شده و فقط داده های سریگ می باشد. داده ها در آزمایشگاه ملی لورنس برکلی از دو روتر به جمع آوری شده اند و شامل ترافیک ورودی، خروجی و مسیریابی واقعی می شوند. این مجموعه داده دارای برچسب نیست و هیچ ویژگی اضافی نیز ایجاد نشده است. ترافیک داخلی و خارجی عمده شامل وب، ایمیل و سرویس های نام دامنه است، در حالی که میزبان های داخلی از سرویس های ویندوز، سرویس های فایل شبکه و پشتیبان گیری نیز استفاده می کنند. ترافیک مخرب عمده شامل درخواست های TCP SYN ناموفق است که نشان دهنده اسکن پورت به مقصد میزبان های LBNL است. برخی اسکن های خروجی نیز وجود دارد. بیشتر ترافیک UDP (ورودی و خروجی) شامل اتصال های موفق است که میزبان ها به جریان های UDP دریافتی پاسخ می دهند.

TUIDS [55]

این مجموعه داده توسط اساتید دانشگاه تربیت هند تولید شده و شامل سناریوهای Scan، Probing، DoS و DDoS در یک محیط آزمایشگاهی است. شبکه تست شامل ۲۵۰ میزبان، ۱۵ سوییچ لایه ۲، هشت سوییچ لایه ۳، سه کنترلر بی سیم و چهار روتر در پنج شبکه مختلف است. داده های سطح جریان فقط شامل ویژگی های تولید شده توسط فرآیند جمع آوری جریان هستند و هیچ ویژگی اضافه ای ساخته نشده است.

InSDN [4]

مجموعه داده InSDN برای ارزیابی واقع گرایانه سامانه های تشخیص نفوذ طراحی شده است. این مجموعه شامل انواع حملات به روز، از جمله DoS، DDoS، brute force، بدافزار، probe، exploit و حملات وب است. همچنین ترافیک معمول برنامه های DNS، HTTP، HTTPS ایمیل، FTP و SSH را دارد. این مجموعه ترکیبی از حملات داخلی و خارجی در SDN است و برای استخراج بیش از ۸۰ ویژگی آماری از استفاده ICICFlowMeter 343,939 رکورد از ترافیک نرم افزاری و مخرب دارد که آن را مشابه شرایط واقعی می کند.

UNB ISCX [20]

این مجموعه داده در مؤسسه امنیت سایبری کانادا تولید شده است. این مجموعه از پروفایل ها برای تعریف تکنیک های حمله و توزیع ترافیک استفاده می کند. تریس های واقعی برای ایجاد پروفایل های دقیق و ارزیابی سامانه های تشخیص نفوذ تحلیل شده اند. داده ها با استفاده از یک بستر آزمایشی واقعی و حملات چند مرحله ای گردآوری شده اند. دو پروفایل α (بر اساس حملات مشخص) و β (بر اساس ترافیک فیلتر شده) برای تولید ترافیک بلاذرنگ در پروتکل های مانند HTTP، SMTP، IMAP، POP3، SSH، SMTP، DNS و FTP استفاده شده اند. سناریوهای مختلف حملات چند مرحله ای نیز برای تولید ترافیک مخرب گنجانده شده است.

UNSW-NB15 [33]

این مجموعه داده در UNSW کانبرا با استفاده از IXIA PerfectStorm ۱۰۰ گیگابایتی در قالب فایل های PCAP است که شامل ۴۹ ویژگی جدید و مجموعاً ۲,۵۴۰,۰۴۴ رکورد در چهار فایل CSV است. این مجموعه داده برای تولید و اعتبارسنجی سیستم های تشخیص نفوذ طراحی شده و در یک محیط مصنوعی شبیه سازی حملات ایجاد شده است.

Bot-IoT [12]

این مجموعه داده ترکیبی از ترافیک معمول IoT و شبکه و همچنین انواع مختلف ترافیک مخرب است که معمولاً توسط باتنت ها استفاده می شود. این مجموعه در یک بستر آزمایشی واقعی ایجاد شده و شامل ویژگی های برچسب گذاری شده برای جریان های حمله، دسته بندی حملات و زیر دسته های آنها برای طبقه بندی چند کلاسه است. ویژگی های اضافی برای افزایش قدرت پیش بینی طبقه بندی ها ایجاد شده اند. با تحلیل آماری، یک زیر مجموعه شامل ۱۰ ویژگی برتر نیز استخراج شده است. این مجموعه داده که در سال ۲۰۱۸ ساخته شده، شامل ۴۶ ویژگی و شش نوع حمله است: اسکن سرویس، اثرا نگاری سیستم عامل، DDoS، DOS، کی لاگر و سرقت داده. با این حال، مجموعه داده نام توازن است؛ برای مثال تنها ۱۱۸ رکورد سرقت داده و ۱۴۶۹ رکورد کی لاگر دارد — مقادیری که برای بسیاری از الگوریتم های یادگیری ماشین کافی نیستند. نقطه قوت مهم این مجموعه داده حضور ترافیک IoT است که در بیشتر مجموعه داده های تشخیص نفوذ وجود ندارد. با وجود غنای ویژگی ها، تعداد نمونه ها برخی حملات و ترافیک عادی کم است.

CICIDS2017 [5]

مجموعه داده CICIDS2017 شامل رفتارهای سالم (benign) و جزئیات انواع بدافزارها و حملات نوظهور مانند FTP، Bruteforce، SSH، DoS، Force، DDoS، Web Attack، Heartbleed، Infiltration، Botnet و Sharafaldin et al. 2018 است. این مجموعه داده با دقت بالا و بر اساس برچسب های مانند زمان، آدرس های IP مبدأ و مقصد، پورت های مبدأ و مقصد، پروتکل ها و نوع حمله مشخص سازی شده است. برای تولید این مجموعه داده، یک توبولوژی شبکه جامع شامل مودم ها، فایروال ها، سوئیچ ها، روترا و گردهای با سیستم عامل های مختلف Windows 10، Windows 8، Windows 7، macOS و لینوکس (ایجاد شد. در مجموع، این مجموعه داده شامل 80 ویژگی جریان شبکه (network flow) استخراج شده از ترافیک ثبت شده است.

CICDDoS2019 [16]

مجموعه داده CICDDoS2019 به طور عمومی در دسترس پژوهشگران و متخصصان امنیت قرار دارد تا بتوانند سیستم های تشخیص نفوذ (IDS) را در برابر تهدیدات در حال تکامل DDoS ارزیابی کنند. این مجموعه داده شامل جدیدترین و رایج ترین انواع حملات DDoS همراه با ترافیک سالم است تا شرایط شبکه واقعی را شبیه سازی کند. برای ایجاد مجموعه ای غنی از ویژگی ها، CICFlowMeter برای استخراج بیش از 80 ویژگی آماری از ترافیک شبکه استفاده شده است. این مجموعه داده دارای بیش از 343,939 رکورد از ترافیک عادی و مخرب است و امکان آموزش جامع مدل های IDS را فراهم می کند.

IoT-23 [35]

مجموعه داده IoT-23 برای پژوهشگران امنیت سایبری که روی حفاظت از اینترنت اشیا کار می کنند بسیار ارزشمند است. این مجموعه داده به طور عمیق روی بدافزارهای مرتبط با دستگاه های IoT تمرکز دارد. مجموعه ای از ترافیک واقعی دستگاه های آلوده و سالم را ارائه می دهد و امکان توسعه الگوریتم های یادگیری ماشین برای تشخیص فعالیت های مخرب را فراهم می کند. در این مجموعه داده 20 نمونه مختلف بدافزار وجود دارد و داده ها با دقت بالا برچسب گذاری شده اند که کار آموزش مدل ها را ساده می کند. این مجموعه داده رایگان و قابل دسترس است.

ToN-IoT [31]

مجموعه داده ToN-IoT که در آزمایشگاه های UNSW کانبرا تولید شده، دیدگاهی جامع درباره امنیت IoT ارائه می دهد. این مجموعه شامل داده های متنوع (heterogeneous data) مانند: داده های تله متري دستگاه های متصل، لاگ های سیستم های لینوکس و ویندوز، و ترافیک شبکه. این مجموعه داده در قالب CSV ارائه شده و شامل برچسب های نرمال و حمله است. حق نوع حمله نیز مشخص شده و شامل مواردی مانند باج افزار، حملات DoS، اسکن ها، انواع XSS و MITM است. این داده ها امکان توسعه مدل های مبتنی بر هوش مصنوعی برای حفاظت از محیط های IoT را فراهم می کند.

SDN Dataset [8]

این مجموعه داده شامل دو بخش است که هر کدام یک نوع شبکه IoT را مدل سازی می کند: شبکه ایستا (Static) با 27.9 میلیون رکورد و شبکه پویا (Dynamic) با 30.2 میلیون رکورد هر دو شامل حملات سایبری و ترافیک سالم بوده و 33 ویژگی دارند. پنج نوع حمله در این مجموعه وجود دارد: DoS، DDoS، اسکن پورت، fuzzing و OS fingerprinting. شبکه با Mininet شبیه سازی و با کنترل ONOS مدیریت شد. شبکه ایستا شامل 5 دستگاه IoT و شبکه پویا شامل 10 دستگاه بود که برخی در طول ضبط داده خاموش می شدند تا سناریوهای مختلف شبکه شبیه سازی شود. استفاده از مجموعه داده های باز امکان باز تولید مدل ها و دستیابی به نتایج سازگار در مطالعات مختلف شبکه را فراهم می کند. این کار شفافیت را افزایش داده و پیشبرد تحقیقات را تسهیل می کند. جدول 8 مروری بر مجموعه داده های باز قابل دسترسی ارائه می دهد که به عنوان پایه های اساسی پژوهش در زمینه تشخیص و کاهش حملات عمل می کند.

۴. راهکارهای کاهش و شناسایی حملات توزیع شده منع سرویس (DDoS)

حملات DDoS همچنان چالش های قابل توجهی برای شبکه هایی که با SDN پیاده سازی شده اند ایجاد می کنند. پژوهشگران پیشرفت های مهمی در توسعه روش های مختلف برای کاهش و شناسایی این حملات داشته اند. اطلاعات ارائه شده در این بخش مروری بر پژوهش های اخیر دارد که بر راهکارهای مؤثر در کاهش و تشخیص حملات تمرکز می کنند. شایان ذکر است که این تکنیک ها به طور مداوم در حال تحول اند، زیرا حملات روزبه روز پیچیده تر می شوند.

جدول ۸: مرور کلی مجموعه‌داده‌های باز

مجموعه‌داده

مقالهٔ پژوهشی استفاده‌کننده از مجموعه‌داده

Dataset	Research paper using dataset
DARPA 98 [46]	As mentioned in [9]
DARPA 99 [47]	[45]
DARPA 2000 [50]	[45]
DARPA 2009 [51]	[49]
KDD99 [40]	[4] and [39]
NSL-KDD [27]	[4, 32, 37] and [38]
DEFCON-8 [52]	As mentioned in [9]
UNIBS [53]	As mentioned in [9]
CAIDA DDoS 2007 [48]	[45]
LBNL [54]	As mentioned in [9]
TUIDS [55]	As mentioned in [9]
InSDN [4]	[4] and [3]
UNB ISCX [20]	[19] and [24]
UNSW-NB15 [33]	[32]
Bot-lot [12]	[9] and [13]
CICIDS2017 [5]	[4] and [3]
CICDDoS 2019 [16]	[15]
IoT-23 [35]	[34]
ToN-IoT [31]	[30]
SDN Dataset [8]	[1]

۱، ۴ شبکه‌های اینترنت اشیا مدیریت شده با SDN

ساریکا و همکاران ۱: راهبرد آن‌ها بر استخراج خودکار ویژگی‌های جریان و طبقه‌بندی دقیق جریان‌های شبکه با استفاده از دسته‌بند جنگل تصادفی در لایهٔ کاربرد SDN استوار است. این روش به آن‌ها اجازه داد طیف گسترده‌ای از حملات را شناسایی کرده و اقدامات اصلاحی را با ایجاد قوانین جدید جریان با اولویت بالا در لایهٔ داده آغاز کنند.

۴، ۲ شناسایی و کاهش حملات DoS و DDoS با استفاده از SDN

گالیانو-براخونس و همکاران ۱۳:

سه سناریو ارائه شد: سناریوی اول میزان مصرف پهنای باند در طول حملهٔ DoS و روند کاهش آن را همراه با مقدار آنتروپی اندازه‌گیری می‌کند. این سناریو از کنترلر Ryu و Mininet استفاده می‌کند. دو سناریوی بعدی از مجموعه‌دادهٔ Bot-IoT برای ارزیابی تشخیص و کاهش حملات DoS در یک محیط IoT استفاده می‌کنند. سناریوی نهایی بر تشخیص و کاهش حملات DDoS در محیط IoT تمرکز دارد.

وانگ و همکاران ۳: پژوهشگران یک روش رهگیری منبع حمله برای شبکه‌های SDN با استفاده از ده ویژگی جهت ردیابی منبع حمله توسعه دادند و مدل ترکیبی یادگیری عمیق CNN-ELM (شبکهٔ عصبی پیچشی و ماشین یادگیری شدید) را معرفی کردند.

شارما و همکاران ۱۹: پژوهشگران یک سیستم حمله و پاسخ به نام OpCloudSec طراحی کردند که برای ساخت مدل جلوگیری از حمله از شبکه باور عمیق استفاده می‌کند.

سالم و همکاران ۱۴: پژوهشگران یک رویکرد دو مرحله‌ای مبتنی بر الگوریتم‌ها برای شناسایی اولیهٔ حملات DDoS ارائه دادند. این رویکرد به هر کاربر در سیستم یک مقدار اعتماد اختصاص می‌دهد و درخواست‌های تعاملی آن‌ها با کنترلر را ثبت می‌کند.

دی آسیس و همکاران ۱۵: پژوهشگران یک سیستم دفاعی بررسی ترافیک با بازه‌های یک‌ثانیه‌ای برای شبکه‌های SDN معرفی کردند که قادر به شناسایی و کاهش حملات DDoS بر روی کنترلر و یک سرور خارجی است. آن‌ها مازلول کاهش را توضیح دادند و یک مثال عملی مبتنی بر نظریه بازی ارائه کردند.

وانی [18]: پژوهشگران مکانیزم امنیتی SDIoT-DDoS-DA را برای شناسایی و کاهش حملات DDoS در شبکه‌های SDN پیشنهاد کردند.

۴،۳ تکنیک‌های شناسایی و کاهش حملات DDoS با استفاده از یادگیری عمیق و یادگیری ماشین

راوی و همکاران 24: پژوهشگران رویکرد جدیدی به نام LEDEM را برای شناسایی حملات DDoS با استفاده از الگوریتم یادگیری ماشین نیمه‌نظراتی معرفی کردند.

۴،۴ سامانه‌های تشخیص نفوذ (IDS) با استفاده از الگوریتم XGBoost

گاد و همکاران 30: پژوهشگران یک IDS برای VANET با استفاده از مجموعه‌داده TON-IoT توسعه دادند و با به کارگیری روش انتخاب ویژگی کایدو(Chi-2)، تعداد ویژگی‌ها را از ۱۰۸ به ۲۰ کاهش داده و کارایی مدل را بهبود بخشیدند.

حنیف و همکاران [32]: پژوهشگران یک IDS برای شناسایی سریع حملات و تصمیم‌گیری فوری طراحی کردند. این سیستم در یک کنترلر IoT ادغام شد تا داده‌های ورودی را ارزیابی کرده و داده‌های مخرب را بلافارصله حذف کند.

۴،۵ رویکردهای هوش مصنوعی و یادگیری ماشین در SDN

ساهو و همکاران 37: پژوهشگران روشی برای شناسایی و کاهش حملات DDoS با استفاده از یک مدل یادگیری ماشین ترکیبی شامل KPCA، SVM و GA طراحی کردند.

۴،۶ حملات در شبکه‌های خودرویی با استفاده از SDN و موارد دیگر

یو و همکاران 45: پژوهشگران یک پلتفرم برای شناسایی و مقابله با حملات DDoS در شبکه‌های خودرویی مبتنی بر SDN ایجاد کردند که از یک تکنیک تشخیص جدول جریان استفاده می‌کند.

مایتی و همکاران 49: پژوهشگران یک سیستم تشخیص DDoS مبتنی بر مدل احتمالاتی ارائه کردند که به جای سرعت ترافیک، از توزیع پرچم‌های TCP در کنترلر برای کاهش نرخ منفی کاذب بهره می‌برد. پژوهشگران تاکنون روش‌های متنوعی برای شناسایی و کاهش حملات ارائه کرده‌اند و از طیف گسترده‌ای از مدل‌های یادگیری ماشین یا ترکیب چند مدل برای افزایش دقت استفاده کرده‌اند. بخش زیر نیز چارچوب‌هایی برای شناسایی و کاهش حملات ارائه می‌کند. تمرکز اصلی این چارچوب‌ها بر حوزه شناسایی و کاهش حملات DDoS است.

۴،۷ تکنیک‌های شناسایی و کاهش حملات DDoS با استفاده از یادگیری عمیق و یادگیری ماشین

پیوم و همکاران 23: پژوهشگران یک چارچوب شناسایی DDoS مبتنی بر LSTM ارائه کردند که از سمت منبع عمل کرده و با استفاده از آستانه‌های تطبیقی مبتنی بر LSTM برای هر شبکه در سمت منبع، مشکلات عملکردی ناشی از رفتار نامنظم ترافیک را کاهش می‌دهد.

۴،۸ شناسایی و کاهش حملات DoS و DDoS با استفاده از SDN

باوانی و همکاران 6: پژوهشگران ProDefence را ایجاد کردند؛ یک چارچوب مأذولار برای شناسایی و مقابله با حملات DDoS در شبکه هوشمند مقیاس بالای مبتنی بر SDN. این چارچوب شامل اجزایی مانند جمع‌آوری کننده جریان ترافیک، موتور سیاست‌گذاری، تشخیص دهنده حمله، و موتور کاهش حمله است.

۴،۹ رویکردهای هوش مصنوعی و یادگیری ماشین در SDN

ژو و همکاران 36: پژوهشگران یک چارچوب برای تولید، استقرار و تنظیم خودکار اقدامات دفاعی پیش‌دستانه در IoT طراحی کردند. این چارچوب بر تکنیک‌های MTD و فریب سایبری تکیه دارد تا مهاجمان را سردرگم کرده و اختلالات را به حداقل برساند.

تان و همکاران 38: برای تشخیص DDoS از یک مکانیزم محرك (trigger) در لایه داده همراه با الگوریتم یادگیری ماشین مبتنی بر کنترلر و استفاده از K-Means و KNN برای شناسایی جریان‌های مشکوک بهره گرفته شد.

رواتی و همکاران 39: پژوهشگران چارچوبی مبتنی بر DSM-SVM برای پیش‌بینی و مقابله با حملات DDoS در SDN ایجاد کردند.

۴. شبکه‌های اینترنت اشیا مدیریت شده با SDN

بهایو و همکاران 10: پژوهشگران یک چارچوب تشخیص حمله DDoS با استفاده از C-DAD تشخیص حمله DDoS با استفاده از SD-IoT طراحی کردند. این الگوریتم از شماست کسینوسی برای مقایسه بردارهای نخ Packet-in استفاده می‌کند.

5. بحث

این مرور، به کاربردهای نوین تکنیک‌ها و چارچوب‌های یادگیری ماشینی در زمینه حملات DDoS در SDN می‌پردازد. این مطالعه بر ماهیت پویای این حوزه تأکید کرده و اهمیت استفاده از جدیدترین پژوهش‌ها برای ایجاد معیارهای تازه و پیشبرد پیشرفت‌ها را بر جسته می‌کند. با وجود تمرکز قابل توجه پژوهش‌ها بر به کارگیری یادگیری ماشینی در امنیت SDN، یکی از چالش‌های اصلی، کمبود مجموعه‌داده‌های عمومی است. این مجموعه‌داده‌ها برای پیشبرد تحقیقات در این حوزه ضروری هستند [7]. مقایسه‌ها نشان می‌دهد که تعداد محدودی مجموعه‌داده باز مختص SDN شناسایی شده است. این مسئله احتمالاً به دلیل کمبود چنین مجموعه‌داده‌هایی در زمان انجام مرور بوده است. هرچند مجموعه‌داده‌های موجود شامل حملات مرتبط هستند، اما اغلب فاقد محیط‌های تست بد مطلوب بوده‌اند. علاوه بر این، پژوهشگران بررسی‌های دریاره تکنیک‌های مقابله با DDoS و چالش‌های امنیتی در SDN انجام داده‌اند [41]. اگرچه برخی از مقالات بررسی‌شده قدیمی‌تر هستند، اما درک جامعی از انواع مختلف حملات DDoS در SDN ارائه می‌دهند. مرور حاضر، با معرف تکنیک‌های اضافی در زمینه تشخیص و کاهش حملات، دانش موجود را گسترش می‌دهد. بررسی ادبیات نشان می‌دهد برخی مجموعه‌داده‌های باز در مطالعه [41] تحلیل نشده‌اند. دلایل مختلفی برای این موضوع وجود دارد. نخست، ممکن است این مجموعه‌داده‌ها قدیمی باشند و حملات یا پیکربندی‌های مرتبط با پژوهش‌های جدید را شامل نشوند. همچنین استانداردهای گذشته همچنان ارزشمند است. با پیشرفت مداوم یادگیری ماشینی و فناوری‌های SDN، انتظار می‌رود مجموعه‌داده‌های به روزتر و مرتبط‌تری در دسترس قرار گیرند تا زمینه را برای تحقیقات دقیق‌تر و ارزیابی بهتر روش‌های تشخیص و کاهش حملات فراهم کنند. در ادامه مسیر، لازم است میان بهره‌گیری از بینش‌های پژوهش‌های قدیمی و استفاده از مجموعه‌داده‌ها و روش‌های نوین، تعادل منطقی برقرار شود تا با چشم‌انداز روبرو تغییر حملات DDoS در محیط‌های SDN سازگار باشد.

6. نتیجه‌گیری و کارهای آینده

در جمع‌بندی، این مقاله مروری جامع بر مجموعه‌داده‌های باز شامل حملات DDoS، و همچنین تکنیک‌ها و چارچوب‌های تشخیص و کاهش حملات ارائه می‌دهد. در دسترس بودن این مجموعه‌داده‌های باز برای ایجاد بستری استاندارد که پژوهشگران بتوانند در آن مشارکت کنند، حیاتی است. میزان اثربخشی و دقیقت پژوهش‌ها در زمینه تشخیص و کاهش حملات، از طریق استفاده از این مجموعه‌داده‌های باز نشان داده می‌شود. مقاله با ارائه مطالعات موردنی عملی، نمونه‌های واقعی از به کارگیری این داده‌ها در توسعه و اعتبارسنجی تکنیک‌های مقابله را نشان می‌دهد و شکاف میان فهم نظری و کاربرد عملی را کاهش می‌دهد. همچنین، مقاله بر استفاده از مجموعه‌داده‌های SDN برای به کارگیری تکنیک‌ها و چارچوب‌های جدیدتر تأکید دارد. علاوه بر این، مقاله یافته‌های خود را با دو مطالعه مروری دیگر که به وضعیت مجموعه‌داده‌های باز و روش‌های تشخیص و کاهش حملات می‌پردازند مقایسه کرده است. این مقایسه، دید عمیق‌تری نسبت به چشم‌انداز پژوهش‌ها فراهم می‌کند. همچنین لازم است تلاش‌هایی برای ایجاد مجموعه‌داده‌های معیار و جامع صورت گیرد؛ مجموعه‌داده‌هایی که طیف گسترده‌ای از سناریوهای حمله، تولوچی‌های شبکه و پیکربندی‌های SDN را شامل شوند. توسعه معیارهای استاندارد ارزیابی نیز به مقایسه‌پذیری و تکرارپذیری نتایج در مطالعات مختلف کمک شایانی خواهد کرد. همکاری‌های گسترده میان دانشگاه، صنعت، و نهادهای امنیت سایبری می‌تواند نقش مهمی در رفع کمبود مجموعه‌داده‌های باز ایفا کند. برای تحقیقات آینده، برنامه‌هایی جهت ایجاد یک مجموعه‌داده SDN با تمرکز ویژه بر حملات DDoS وجود دارد. این مجموعه‌داده با استفاده از یک تست بد SDN ایجاد و ارزیابی خواهد شد و نتایج آن با مجموعه‌داده‌های دیگر شامل حملات DDoS مقایسه می‌شود. این اقدام می‌تواند به پیشبرد تحقیقات در زمینه SDN و افزایش کارایی روش‌های تشخیص و کاهش حملات کمک کند.

قدردانی(Acknowledgements)

این پژوهش بر مبنای کاری انجام شده است که با حمایت ONR شماره جایزه N00014-22-1-2724: تأمین شده است. دیدگاهها و نتایج مطرح شده در اینجا متعلق به نویسندها است و نباید لزوماً به عنوان بازتاب سیاست‌ها یا تأییدهای رسمی دولت ایالات متحده، چه به صورت صریح و چه ضمنی، تعبیر شوند.

مشارکت نویسندها(Author contributions)

W متن اصلی دست‌نوشته را تهیه کرده است و تمامی نویسندها آن را بازبینی کرده‌اند.

JM ، SP ، CC ، YA ، KR مشارکت‌های قابل توجهی در ایده‌پردازی یا طراحی کار؛ یا گردآوری، تحلیل، یا تفسیر داده‌ها؛ یا ایجاد نرم‌افزار جدید مورد استفاده در این پژوهش داشته‌اند WH . ، YA ، JM ، KR ، DL پیش‌نویس کار را تهیه کرده یا آن را از نظر محتوای علمی مهم، به‌طور انتقادی بازنگری کرده‌اند KR و WH نسخهٔ نهایی برای انتشار را تأیید کرده‌اند و موافقت دارند که مسئولیت تمام جنبه‌های کار را بر عهده بگیرند تا اطمینان حاصل شود که هرگونه پرسش دربارهٔ صحت یا یکپارچگی هر بخش از کار، به درستی بررسی و حل و فصل می‌شود.

تأمین مالی(Funding) برای این مطالعه هیچ بودجه‌ای دریافت نشده است.

دسترسی‌پذیری داده‌ها و مواد(Availability of data and materials)

داده‌های استفاده شده در این پژوهش در مخازن عمومی در دسترس هستند. اطلاعات دقیق در بخش تحلیل نتایج ارائه شده است.

بیانیه‌ها(Declarations)

منافع متعارض(Competing interests) نویسندهان اعلام می‌کنند که هیچ تضاد منافع ندارند.

دسترسی آزاد(Open Access)

این مقاله تحت مجوز Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International منتشر شده است. این مجوز هرگونه استفاده غیرتجاری، اشتراک‌گذاری، توزیع و تکثیر در هر رسانه یا قالبی را مجاز می‌داند، به شرطی که: اعتبار مناسب به نویسندها اصلی و منبع داده شود، پیوندی به مجوز Creative Commons ارائه شود، و اگر تغییری در محتوای دارای مجوز داده شده باشد، اعلام شود. تحت این مجوز، شما اجازه ندارید نسخه‌های اصلاح شده این مقاله یا بخش‌هایی از آن را منتشر یا به اشتراک بگذارید. تصاویر یا سایر مواد متعلق به اشخاص ثالث موجود در مقاله، تحت مجوز Creative Commons مقاله قرار دارند مگر اینکه در خط اعتباری (credit line) خلاف آن ذکر شده باشد. اگر بخشی از مواد موجود در مقاله تحت مجوز Creative Commons نباشد و استفاده شما مجاز نباشد یا فراتر از حدود استفاده قانونی قرار گیرد، لازم است مستقیماً از صاحب حق نشر اجازه بگیرید. برای مشاهده نسخه این مجوز، به وب‌سایت / <http://creativecommons.org/licenses/by-nc-nd/4.0/> مربوطه مراجعه کنید.

منابع

.1 Sarica AK, Angin P. Explainable security in SDN-based IoT networks. Sensors. 2020;20(24):7326. <https://doi.org/10.3390/s20247326>.

.2 Stephen MS. Distributed denial of service: taxonomies of attacks, tools and countermeasures. Electrical Engineering Princeton University;

.2004

.3 Wang J, Wang L. SDN-defend: a lightweight online attack detection and mitigation system for DDoS attacks in SDN. Sensors.

- .8287:(21)22;2022https://doi.org/10.3390/s22218287.
- .4Elsayed MS, Le-Khac N-A, Jurcut AD. InSDN: a novel SDN intrusion dataset. *IEEE Access*. 2020;8:165263–84. <https://doi.org/10.1109/ACCESS>.
- .2020.3022633
- .5CIC-IDS2017. University of New Brunswick est.1785. (n.d.-a). <https://www.unb.ca/cic/datasets/ids-2017.html>.
- .6Bawany NZ, Shamsi JA, Salah K. DDoS attack detection and mitigation using SDN: methods, practices, and solutions. *Arab J Sci Eng*.
- .41–42:425;2017
- .7Gebremariam AA, Usman M, Qaraqe M. Applications of artificial intelligence and machine learning in the area of SDN and NFV: a survey. In: 2019 16th International multi-conference on systems, signals & devices (SSD), Istanbul, Turkey; 2019, pp. 545–549. <https://doi.org/10.1109/SSD.2019.8893244>.
- .8Sarica AK, Angin P. A novel SDN dataset for intrusion detection in IoT networks. In: 2020 16th International conference on network and service management (CNSM); 2020, pp. 1–5. <https://doi.org/10.23919/CNSM50824.2020.9269042>.
- .9Koroniots N, Moustafa N, Sitnikova E, Turnbull B. Towards the development of realistic botnet dataset in the Internet of Things for network forensic analytics: Bot-IoT Dataset; 2018.
- .10Bhayo J, Hameed S, Shah SA. An efficient counter-based DDoS attack detection framework leveraging software defined IoT (SD-IoT). *IEEE Access*. 2020;8:221612–31.
- .11Yin D, Zhang L, Yang K. A DDoS attack detection and mitigation with software-defined Internet of Things framework. *IEEE Access*.
- .705–6:24694;2018
- .12The Bot-IOT dataset. The Bot-IoT Dataset | UNSW Research. (n.d.). <https://research.unsw.edu.au/projects/bot-iot-dataset>.
- .13Galeano-Brajones J, Carmona-Murillo J, Valenzuela-Valdés JF, Luna-Valero F. Detection and mitigation of DoS and DDoS attacks in IoT-based stateful SDN: an experimental approach. *Sensors*. 2020;20(3):816.
- .14Salem FM, Youssef H, Ali I, Haggag A. A variable-trust threshold-based approach for DDoS attack mitigation in software-defined networks. *PLoS ONE*. 2022;17(8):e0273681.

.15de Assis MV, Carvalho LF, Rodrigues JJ, Lloret J, Proen  a ML Jr. Near real-time security system applied to SDN environments in IoT networks

using convolutional neural network. *Comput Electr Eng.* 2020;86:106738.

.16CIC-DDoS2019. University of New Brunswick est.1785. (n.d.-a). <https://www.unb.ca/cic/datasets/ddos-2019.html>.

.17Kiani R, Bohlooli A. Distributed rule anomaly detection in SDN-based IoT. In: 2021 5th International conference on Internet of Things and

applications (IoT). IEEE; 2021, pp. 1–6.

.18Wani A, Revathi S. DDoS detection and alleviation in IoT using SDN (SDIoT-DDoS-DA). *J Inst Eng (India) Ser B.* 2020;101(2):117–28. <https://doi.org/10.1007/s40031-020-00442-z>.

.19Sharma PK, Singh S, Park JH. OpCloudSec: open cloud software-defined wireless network security for the Internet of Things. *Comput*

Commun. 2018;122:1–8.

.20UNB ISCX. University of New Brunswick est.1785. (n.d.-b). <https://www.unb.ca/cic/datasets/ids.html>.

.21Singh J, Behal S. Detection and mitigation of DDoS attacks in SDN: a comprehensive review, research challenges and future directions.

Comput Sci Rev. 2020;37:100279.

.22Singh MP, Bhandari A. New-flow based DDoS attacks in SDN: taxonomy, rationales, and research challenges. *Comput Commun.*

.27–154:509;2020

.23Yeom S, Choi C, Kim K. LSTM-based collaborative source-side DDoS attack detection. *IEEE Access.* 2022;10:44033–45.

.24Ravi N, Shalinie SM. Learning-driven detection and mitigation of DDoS attack in IoT via SDN-cloud architecture. *IEEE Internet Things J.*

.70–3559:(4)7;2020

.25Santos R, et al. Machine learning algorithms to detect DDoS attacks in SDN. *Concurr Comput Pract Exp.* 2020;32(16):e5402. <https://doi.org/10.1002/cpe.5402>.

.26Nadeem MW et al. DDoS detection in SDN using machine learning techniques. *Comput Mater Continua.* 71(1) (2022). https://cdn.techsciencenetwork.com/ueditor/files/cmc/TSP_CMC-71-1/TSP_CMC_21669/TSP_CMC_21669.pdf.

.27NSL-KDD Dataset. University of New Brunswick est.1785. (n.d.). <https://www.unb.ca/cic/datasets/nsl.html>.

.28Banitalebi Dehkordi A, Soltanaghaei MR, Boroujeni FZ. The DDoS attacks detection through machine learning and statistical methods in

SDN. J Supercomput. 2021;77(3):2383–415.

.29Perez-Diaz JA, et al. A flexible SDN-based architecture for identifying and mitigating low-rate DDoS attacks using machine learning. IEEE

Access. 2020;8:155859–72.

.30Gad AR, Nashat AA, Barkat TM. Intrusion detection system using machine learning for vehicular ad hoc networks based on ToN-IoT dataset.

IEEE Access. 2021;9:142206–17.

.31The Ton_IoT datasets. The TON_IoT Datasets | UNSW Research. (n.d.).
<https://research.unsw.edu.au/projects/toniot-datasets>.

.32Hanif S, Ilyas T, Zeeshan M. Intrusion detection in IoT using artificial neural networks on UNSW-15 dataset. In: 2019 IEEE 16th international

conference on smart cities: improving quality of life using ICT & IoT and AI (HONET-ICT). IEEE; 2019, pp. 152–156.

.33The UNSW-NB15 Dataset | UNSW Research—UNSW sites. (n.d.).
<https://research.unsw.edu.au/projects/unsw-nb15-dataset>.

.34da Cruz MA, Abbade LR, Lorenz P, Mafra SB, Rodrigues JJ. Detecting compromised IoT devices through XGBoost. IEEE Trans Intell Transp Syst. 2022;24:15392–9.

.35IOT-23 dataset: A labeled dataset of malware and benign IOT traffic. Stratosphere IPS. (n.d.).
<https://www.stratosphereips.org/datasets-iot23>.

.36Zhou Y, Cheng G, Yu S. An SDN-enabled proactive defense framework for DDoS mitigation in IoT networks. IEEE Trans Inf Forensics Secur. 2020;15:5366–80.

.37Sahoo KS, Tripathy BK, Naik K, RamasubbaReddy S, Balusamy B, Khari M, Burgos D. An evolutionary SVM model for DDoS attack detection

in software-defined networks. IEEE Access. 2020;8:132502–13.

.38Tan L, Pan Y, Wu J, Zhou J, Jiang H, Deng Y. A new framework for DDoS attack detection and defense in SDN environment. IEEE Access.

.39Revathi M, Ramalingam VV, Amutha B. A machine learning based detection and mitigation of the DDOS attack by using SDN controller

framework. *Wirel Pers Commun.* 2021;127:2417–41.

.40KDD Cup 1999 Dataset. KDD Cup 1999 Data. (n.d.).
<http://kdd.ics.uci.edu/databases/kddcup99/kddcup99.html>.

.41Fajar AP, Purboyo TW. A survey paper of distributed denial-of-service attack in software defined networking (SDN). *Int J Appl Eng Res.* 2018;82–476:(1)13;2018

.42Tan L, et al. A new framework for DDoS attack detection and defense in SDN environment. *IEEE Access.* 2020;8:161908–19.

.43Ali TE, Chong Y-W, Manickam S. Machine learning techniques to detect a DDoS attack in SDN: a systematic review. *Appl Sci.* 2023;13(5):3183.

.44Gadze JD, et al. An investigation into the application of deep learning in the detection and mitigation of DDOS attack on SDN controllers. *Technologies.* 2021;9(1):14.

.45Yu Y, Guo L, Liu Y, Zheng J, Zong YUE. An efficient SDN-based DDoS attack detection and rapid response platform in vehicular networks. *IEEE Access.* 2018;6:44570–9.

1998 .46DARPA Intrusion Detection Evaluation Dataset. MIT Lincoln Laboratory. (n.d.-a).
<https://www.ll.mit.edu/r-d/datasets/1998-darpa-intrusion-detection-evaluation-dataset>.

1999 .47DARPA Intrusion Detection Evaluation Dataset. MIT Lincoln Laboratory. (n.d.-b).
<https://www.ll.mit.edu/r-d/datasets/1999-darpa-intrusion-detection-evaluation-dataset>.

.48Center of applied internet data analysis. <https://www.caida.org/data/>

.49Maity P, Saxena S, Srivastava S, Sahoo KS, Pradhan AK, Kumar N. An effective probabilistic technique for DDoS detection in OpenFlow controller. *IEEE Syst J.* 2021;16(1):1345–54.

2000 .50DARPA intrusion detection scenario specific datasets. MIT Lincoln Laboratory. (n.d.-c).
<https://www.ll.mit.edu/r-d/datasets/2000-darpa-intrusion-detection-scenario-specific-datasets>.

.51DARPA_2009. The ant lab: Analysis of network traffic. (n.d.).
https://ant.isi.edu/datasets/readmes/DARPA_2009_DDoS_attack-2009.1105.

README.txt.

.52Defcon, “The Shmoo Group,” <http://cctf.shmoo.com/>, 2011.

.53UNIBS, University of Brescia Dataset (2009). <http://www.ing.unibs.it/ntw/tools/traces./>

.54Lawrence Berkley National Laboratory (LBNL), ICSI, LBNL/ICSI enterprise tracing project (2005). <http://www.icir.org/enterprise-tracing./>

.55Bhuyan MH, Bhattacharyya DK, Kalita JK. Towards generating real-life datasets for network intrusion detection. Int J Netw Secur.

.701–17:683;2015

یادداشت ناشر

اسپرینگر نیچر نسبت به ادعاهای قضایی مطرح شده در نقشه‌های منتشرشده و وابستگی‌های سازمانی، پی‌طرف باقی می‌ماند.